

Serverlose und verteilte Softwarearchitektur in einer Microservice-Umgebung (V3)

PHILIPP HAIDER



MASTERARBEIT

eingereicht am
Fachhochschul-Masterstudiengang

Software Engineering

in Hagenberg

im Juli 2017

Erklärung

Ich erkläre eidesstattlich, dass ich die vorliegende Arbeit selbstständig und ohne fremde Hilfe verfasst, andere als die angegebenen Quellen nicht benutzt und die den benutzten Quellen entnommenen Stellen als solche gekennzeichnet habe. Die Arbeit wurde bisher in gleicher oder ähnlicher Form keiner anderen Prüfungsbehörde vorgelegt.

Hagenberg, am 7. Juli 2017

Philipp Haider

Inhaltsverzeichnis

Erklärung	i
1 Microservices	1
1.1 Was ist ein Microservice	1
1.1.1 Monolithischer Ansatz	2
1.2 Charakteristiken von Microservices	4
1.2.1 Organisation um Geschäftskompetenzen	4
1.2.2 Modularisierung durch Dienste	4
1.2.3 Dezentrale Datenverwaltung	5
1.2.4 Automatisierung	7
1.2.5 Größe	7
1.3 Vorteile	8
1.3.1 Heterogener Technologieeinsatz	8
1.3.2 Robustheit	9
1.3.3 Einfaches Deployment	9
1.4 SOA	10
1.5 Zusammenfassung	10
2 Container-Technologien	12
2.1 Unveränderbarer Server	13
2.2 Arten von Virtualisierung	13
2.3 Isolation versus Effizienz	14
2.4 Docker	15
2.4.1 Begriffserklärung	15
2.4.2 Docker-Architektur	15
2.4.3 Voraussetzungen für Betriebssystemvirtualisierung . .	16
2.4.4 Docker Beispiel	17
2.5 Microsoft Windows Container	18
2.6 Containerverwaltung	19
2.6.1 Funktionalität	20
2.6.2 Verteilte Betriebssysteme	20
2.6.3 Marktanalyse	21
2.7 Zusammenfassung	21

3	Serverlose Softwarearchitektur	23
3.1	Arten serverloser Softwarearchitektur	24
3.2	Functions-as-a-Service	24
3.2.1	Anwendungsgebiete	25
3.2.2	Beziehung zu Platform-as-a-Service	26
3.2.3	Markt	27
3.3	Azure-Functions	27
3.3.1	Azure-App-Service	28
3.3.2	Site-Control-Manager	28
3.3.3	Web-Jobs-SDK	29
3.3.4	Bindungen	30
3.3.5	Web-Jobs-Script-SDK	32
3.3.6	Azure-Function-App	35
3.3.7	Verrechnungsmodell	36
3.3.8	Kaltstart	37
3.3.9	Zusammenfassung	37
3.4	Evolution der Anwendungsentwicklung	38
3.4.1	Automatisierung der Softwareauslieferung	39
3.4.2	Leistungsverbesserung der Hardware	40
3.4.3	Organisatorische Veränderungen	40
3.4.4	Von Microservices zu serverlosen Anwendungen	41
	Quellenverzeichnis	42
	Literatur	42
	Online-Quellen	44

Kapitel 1

Microservices

Der Begriff *Microservices* stiftet derzeit noch große Verwirrung. Nicht nur weil er relativ neu ist, sondern auch weil er sehr breit gefächert ist und eine klare Abgrenzung kaum möglich ist. Im nachfolgenden Kapitel wird der Begriff *Microservice* ausführlich definiert, beschrieben und zu anderen Konzepten abgegrenzt.

1.1 Was ist ein Microservice

Der Begriff *Microservice* ist aus den Wörtern „Micro“ – also klein – und „Service“ zusammengesetzt. Ein Service, oder gleichbedeutend auch Dienst, bezeichnet in der Softwareentwicklung einen Mechanismus zum Bereitstellen von Ressourcen und Funktionen [Mac+06, S. 12]. Der sogenannte Service-Anbieter stellt den Service beliebigen, teilweise unbekannten, Service-Konsumenten zur Verfügung. Die Schnittstelle des Service ist in der Service-Beschreibung eindeutig festgelegt und den Service-Konsumenten bekannt.

Hinter *Microservices* verbirgt sich keine konkrete Technologie oder ein Konzept, das aktiv entwickelt wurde. Vielmehr ist es ein Sammelbegriff, der nachträglich für über die Jahre entstandener Praktiken, Methoden und Technologien im Umfeld von komplexen Softwaresystemen eingeführt wurde. Am häufigsten ist mit *Microservices* die sogenannte *Microservice-Architektur* gemeint. Charakteristisch für dieses Softwarearchitekturmuster ist die Zerlegung eines Softwaresystems in kleine, autonome Dienste, die über ein leichtgewichtiges Kommunikationsprotokoll miteinander kommunizieren. Die Fähigkeiten eines einzelnen Dienstes ist genau auf die Geschäftsanforderungen eines bestimmten Unternehmens oder Einsatzgebietes zugeschnitten [Fowc]. Die Verwendung dieses Muster bringt aber neben technischen Einflüssen meistens auch organisatorische Einflüsse mit sich. Die *Microservice-Architektur* hat Auswirkungen auf die Teamstruktur, Verantwortung, Continuous Integration, Testen und viele andere Bereiche. Daher können mit dem Begriff *Microservices* viele verschiedene Aspekte gemeint sein.

Um den rasanten Verbreitung der Microservice Architektur zu verstehen, ist es notwendig die klassische Architektur derartiger Systeme zu kennen. Dazu beschreibt der nächste Abschnitt den sogenannten monolithischen Ansatz, die damit verbundenen Probleme und Herausforderungen.

1.1.1 Monolithischer Ansatz

Mittlerweile haftet der monolithischen Softwarearchitektur ein negativer Ruf an. Jedoch zu Unrecht, da dieser Ansatz seit Jahrzehnten in vielen Bereichen der Softwareentwicklung sehr gut funktioniert. Im Java- und .NET-Umfeld war bzw. ist dieser Ansatz noch immer gängige Praxis. Dennoch wird er vielerorts von der Microservice-Architektur abgelöst. Doch was macht eine Anwendung überhaupt zu einer monolithischen Anwendung?

Unter einer monolithischen Anwendung versteht man in der Softwareentwicklung eine Anwendung, die verschiedene Geschäftsbereiche oder Funktionalitäten vereint [Fowc]. Intern kann die Applikation z. B. als Mehrschicht-Architektur organisiert sein. Üblich ist eine Drei-Schicht-Architektur mit folgenden Bestandteilen [Fow02, S. 19]:

- **Präsentationsschicht:** Hier ist jener Quelltext angesiedelt, der sich mit der Darstellung der Benutzerschnittstelle, z. B. in Form einer Web- oder Desktop-Anwendung auseinandersetzt.
- **Geschäftslogikschicht:** Diese Schicht stellt den Kern der Anwendung dar. Sie enthält alle geschäftsrelevanten Funktionen.
- **Datenzugriffsschicht:** In dieser Schicht befindet sich die Funktionalität, die zum Zugriff auf externe Datenquellen, wie z. B. einer relationalen Datenbank, notwendig ist.

Abbildung 1.1 zeigt den Aufbau einer monolithischen Anwendung mit Drei-Schicht-Architektur, in der jede Schicht nur auf die nächst tiefere zugreifen darf. Innerhalb jeder Schicht ist eine Modularisierung in verschiedene Bereiche, die auf die Geschäftsfunktionen abgestimmt sind, sinnvoll.




Abbildung 1.1: Drei-Schicht-Architektur




Abbildung 1.2: Skalieren einer monolithischen Anwendung

Nachteile und Schwierigkeiten

Mit steigender Komplexität der Software kommen nach und nach Probleme zum Vorschein, die diesen Ansatz aufwändig oder sogar unpraktikabel machen. Eine der größten Herausforderungen bei der Entwicklung von Anwendungen mit globaler Reichweite ist die Skalierbarkeit. Die einzige Möglichkeit, eine monolithische Anwendung zu skalieren, ist auf mehreren Servern jeweils eine Instanz der Anwendung zu installieren und über einen Load-Balancer zu verbinden. Abbildung 1.2 zeigt, wie ein solcher Aufbau aussehen kann. In vielen Einsatzgebieten ist dieser Ansatz aber nicht feingranular genug. Oft ist es sinnvoller, nur bestimmte Teile des Gesamtsystems zu skalieren.

Ein Monolith stößt aber nicht nur aus technischer Sicht auf Skalierbarkeitsprobleme, sondern auch aus organisatorischer Sicht. Alle Entwickler arbeiten zwangsläufig an der gleichen Codebasis, die dadurch enorme Größe annehmen kann. Kein einzelner Entwickler ist mehr in der Lage, die ganze Codebasis zu überblicken und zu beurteilen, welche Auswirkung eine Änderung haben kann. Das führt über kurz oder lang zur Verlangsamung der Entwicklungsgeschwindigkeit oder sogar zu völligem Stillstand.

Anforderungen an eine Software ändern sich häufig sehr rasch. Agile Softwareprozesse unterstützen dabei, die geänderten Anforderungen zeitnahe in die Software einfließen zu lassen. Für den Kunden bzw. Endbenutzer zählt nur die schnellstmögliche Umsetzung seiner neuen Anforderungen. In einer monolithischen Anwendung sind mehrere Geschäftsbereiche zusammengefasst. Somit muss die Anwendung immer als ganzes getestet und ausgerollt werden. Dadurch verlangsamt sich der gesamte Releasezyklus auf den langsamsten Teilbereich, obwohl vielleicht der geänderte Teilbereich schon längst fertiggestellt ist.

Hinter einer monolithischen Anwendung steht immer eine oder mehrere bestimmte Technologien, wie z. B. Java EE oder ASP.NET. Somit müssen alle Teilbereiche der Anwendung auf die selben Technologien zurückgreifen. Für manche Teilbereiche könnte aber möglicherweise die Verwendung von alternativen Technologien und Speichersystemen große Vorteile bringen.

In diesem Abschnitt wurden einige der Hauptkritikpunkte am monolithischen Architekturmuster angeführt. Es mag den Anschein vermittelt haben, dass dieser Ansatz nicht mehr verwendet werden soll oder veraltet ist. Aber das ist so nicht der Fall. Viele Experten sind der Meinung, dass gerade am Anfang eines Projekts der monolithische Ansatz zu bevorzugen ist [Fowe]. Erst nachdem das Verständnis für die Domäne vorhanden ist und Anforderungen klarer sind, ist der fließende Übergang zu einer Microservice Architektur einfacher und sinnvoll.

1.2 Charakteristiken von Microservices

Dieser Abschnitt beschreibt einige charakteristische Merkmale eines Microservice. Wie bereits erwähnt, gibt es keine eindeutige Definition eines Microservice. Daher ist es sinnvoller, allgemeine anerkannte Charakteristiken der Microservice-Architektur zu betrachten.

Fowler identifizierte in [Fowc] neun Charakteristiken von Microservices. Obwohl diese Liste bereits sehr umfangreich ist, sind immer wieder sinnvolle Ergänzungen, wie in [Hor16, S. 3-9] zu finden. Die nachfolgenden Abschnitte beschreiben eine repräsentative Auswahl dieser Charakteristiken.

1.2.1 Organisation um Geschäftskompetenzen

Softwareentwickler sind normalerweise anhand ihrer technologischen Spezialisierung z. B. in folgende Teams eingeteilt:

- Front-End-Entwickler
- Backend-End-Entwickler
- Datenbank-Spezialisten
- Infrastruktur-Spezialisten

Durch die Microservice-Kultur hat sich aber eine andere Art der Teamstrukturierung etabliert. Für jede Geschäftskompetenz ist genau ein Team, welches intern aus einer kleinen Anzahl an den eingangs genannten Technologieexperten besteht, verantwortlich. Damit soll die Identifizierung und das Verantwortungsbewusstsein jedes einzelnen Teammitglieds für den von ihm entwickelten und betriebenen Dienst gestärkt werden.

Was aber dennoch eine große Herausforderung bleibt, ist die Definition des Aufgabenbereichs eines einzelnen Teams. Die Identifikation und Abgrenzung der Geschäftskompetenzen eines Unternehmens ist eine sehr komplexe Aufgabe. Als Hilfsmittel lässt sich hier das Single-Responsibility-Principle heranziehen [Mar06, S. 116]:

A class should have only one reason to change.

Das aus der objektorientierten Programmierung bekannte Entwurfsprinzip kann auch im Kontext von Microservices angewandt werden. Es erweitert diesen Grundsatz von der Klassen-Ebene auf die Dienst-Ebene. Das heißt, jeder Dienst soll genau eine Fähigkeit realisieren. Damit ist sichergestellt, dass geänderte Geschäftsanforderungen so wenig wie möglich andere Microservices beeinflussen.

1.2.2 Modularisierung durch Dienste

Seit Jahrzehnten strebt die Softwareentwicklungsbranche danach, komplexe Softwaresysteme einfach durch die Integration verschiedener Komponenten

realisieren zu können. Durch die vielen über Jahre hinweg entwickelten Ansätze, ist leider auch der Begriff Komponente sehr überstrapaziert und hat dementsprechend viele unterschiedliche Bedeutungen. Beispielsweise kann in der objektorientierten Programmierung eine Klasse als Komponente betrachtet werden. Im Java-Umfeld werden *Enterprise Java Beans* gerne als verteilte Komponenten bezeichnet. In anderen Bereichen wiederum wird der Begriff für ein Software-Modul verwendet.

Auch wenn die konkrete Umsetzung einer Komponente sehr vielfältig sein kann, haben alle Ansätze dieselben Ziele:

- **Austauschbarkeit:** Es soll möglich sein, eine Komponente durch eine andere zu ersetzen.
- **Wiederverwendbarkeit:** Eine entwickelte Komponente soll auch in anderen Systemen wiederverwendet werden können.
- **Aktualisierbarkeit:** Durch die Austauschbarkeit ist es automatisch möglich, eine Komponente durch eine neuere Version zu ersetzen, ohne den Rest der Anwendung zu beeinflussen.

Im Kontext der monolithischen Softwarearchitektur sind am häufigsten die Begriffe Modul oder Software-Bibliothek ein Synonym für den Begriff Komponente. Eine Anwendung besteht somit aus einer Menge von Modulen, die miteinander verbunden sind. Leider erfüllt dieser Ansatz die zuvor beschriebenen gewünschten Eigenschaften der Komponenten-Orientierung nicht ganz zufriedenstellend. Abhängigkeiten zwischen den einzelnen Modulen oder bestimmte Voraussetzungen an das Laufzeitsystem der monolithischen Anwendung können das Aktualisieren eines Moduls wesentlich erschweren. Somit sind die verwendeten Komponenten nicht völlig voneinander unabhängig, sondern haben versteckte Abhängigkeiten.

In einer Microservice-Architektur wird die Modularisierung eines Softwaresystems, durch die Zerlegung in mehrere Services erreicht. Im Unterschied zu einer Komponente, stehen bei einem Service die Bedürfnisse des Service-Konsumenten im Vordergrund. Jeder Service ist ein eigener Prozess, der über ein Kommunikationsprotokoll mit anderen Services und seinen Konsumenten interagiert. Mit diesem Ansatz lassen sich die gewünschten Eigenschaften viel leichter realisieren.

1.2.3 Dezentrale Datenverwaltung

Eine monolithische Anwendung legt sehr häufig alle persistenten Daten in einer einzigen relationalen Datenbank ab. Jeder Programmteil greift einfach auf die benötigten Daten direkt zu. Dieser Ansatz ist in Abbildung 1.3 dargestellt. In einer Microservice-Architektur ist dieser Ansatz nicht mehr empfehlenswert. Persistente Daten eines bestimmten Geschäftsbereichs sollen nur von einem einzigen Dienst verwaltet werden. Direkter Zugriff auf diese Daten durch andere Dienste führt zu unerwünschten Abhängigkeiten.

Andere Dienste müssen Daten über die öffentliche Schnittstelle des zuständigen Microservices abfragen oder verändern.




Abbildung 1.3: Zentraler Datenspeicher

Wenn jeder Dienst wie in Abbildung 1.4 seinen eigenen Datenspeicher besitzt, kann für die Erfüllung seiner Aufgabe der optimale Speichermechanismus ausgewählt werden. Beispielsweise können Daten mit komplexen Beziehungen in einer Graphdatenbank abgelegt werden, einfache Daten jedoch in einem schnellen Key-Value-Speicher.




Abbildung 1.4: Polyglot Persistence

Auch eine monolithische Anwendung könnte Gebrauch von mehreren Datenbanken machen. Dieser Ansatz ist unter dem Namen *Polyglot Persistence* bekannt [Fowf]. Aus teilweise sehr vielfältigen Gründen ist er aber selten anzutreffen. Dazu zählen beispielsweise folgende:

- Die IT-Strategie einiger Unternehmen sehen nur die Verwendung ganz bestimmter Datenbanken vor.
- Bereits getätigte Investitionen in bestehende Datenbanksysteme müssen amortisiert werden.
- Angst vor dem Betrieb einer Datenbank, für die noch nicht die notwendige Erfahrung aufgebaut wurde.

Für Systeme mit hohen Anforderungen an die Verfügbarkeit ist die Verwendung einer einzigen Datenbank nicht ausreichend. Denn eine einzige Datenbank stellt einen kritischen *Single Point of Failure* dar.

Eine zentrale Datenbank ist aber keinesfalls ein Antimuster, sondern in vielen Fällen die richtige Entscheidung. In verteilten Szenarien wird meistens die Konsistenz zugunsten der besseren Verfügbarkeit und Skalierbarkeit eingeschränkt. Aber diese Einschränkung ist nicht in jedem Szenario akzeptabel. Das *CAP-Theorem* von Brewer besagt, dass in einem verteilten System nur zwei der drei Eigenschaften Verfügbarkeit, Konsistenz und Ausfalltoleranz gleichzeitig erreicht werden können [Bre00]. Somit ist eine zentrale Datenbank, für Anwendungen in denen es besonders auf Konsistenz und Verfügbarkeit ankommt, immer noch eine gute Wahl.

1.2.4 Automatisierung

Für ein erfolgreiches System, das aus Microservices besteht, ist ein hoher Grad an Automatisierung erforderlich. Durch die große Anzahl an Komponenten im System, muss die Anzahl an manuell erforderlichen Schritten sehr gering sein. Ansonsten ist der Aufwand für das Aktualisieren, Ausrollen, Testen und Überwachen viel zu groß.

Um von den Vorteilen der Microservice-Architektur gegenüber einer monolithischen zu profitieren, ist es erforderlich, jeden Dienst einzeln ausrollen zu können. Denn nur so sind die Entwicklungs- und Releasezyklen der einzelnen Dienste einer Applikation voneinander unabhängig.

Wenn jeder Dienst einzeln ausgerollt werden kann, ist es auch möglich, unterschiedliche Versionen gleichzeitig zu betreiben. Somit kann eine neue Version getestet werden und erst wenn diese Testphase erfolgreich abgeschlossen ist, der gesamte Datenverkehr auf diesen Dienst umgeleitet werden. Bei Problemen kann schnell der ursprüngliche Zustand wiederhergestellt werden. Insgesamt mindert ein derartiges Vorgehen das Risiko eines großen Big-Bang-Deployments.

Damit dieser Ansatz funktioniert, müssen die Dienste einige Anforderungen erfüllen. Jeder Dienst steht mit einigen anderen in Verbindung. Wenn nun eine neue Version eines Dienstes ausgerollt wird, muss dessen Schnittstelle abwärtskompatibel sein, da seine Konsumenten noch die alte Schnittstelle verwenden. Fehlertoleranz ist eine weitere wichtige Eigenschaft, da während eine neue Version ausgerollt wird, der Dienst kurzzeitig nicht verfügbar sein kann.

1.2.5 Größe

Wie der Name bereits suggeriert, soll ein Microservice klein sein. Das sollte schon durch die Anwendung des *Single-Responsibility* Prinzips aus Abschnitt 1.2.2 gegeben sein. Wie groß ein Dienst genau sein soll, lässt sich aber aus vielen Gründen schwer festlegen. Die Anzahl der Quelltextzeilen ist ein schlechtes Maß für die Größe, da sie je nach Programmiersprache stark variiert. Schon aussagekräftiger ist die benötigte Zeitdauer für die Entwicklung

des Dienstes. Aber auch diese Kennzahl kann trügerisch sein. Beispielsweise kann man mit der Verwendung von externen Bibliotheken eine große Zeiterparnis erzielen. Jedoch inkludiert der Service dann auch die Komplexität dieser Bibliothek.

Eine genaue domänen-unabhängige Größenangabe ist praktisch nicht möglich. Es kann lediglich ein grober Rahmen abgesteckt werden. Ein Microservice sollte eine Entwicklungszeit von mehreren Wochen nicht übersteigen.

Neben quantitativen Kennzahlen sind oft subjektive Kriterien erforderlich. Eine davon ist, dass ein einzelner Entwickler die gesamte Funktionalität eines Dienstes noch im Kopf behalten können muss. Sobald es keinen einzelnen Menschen mehr gibt, der alle Aspekte des Dienstes auf einmal überschauen kann, ist er auf jeden Fall zu groß. Meistens aber haben erfahrene Architekten und Entwickler ein sehr gutes Gefühl, ab welcher Größe ein Dienst zu groß ist.

1.3 Vorteile

Ein neuer Softwareentwicklungsansatz setzt sich nur dann durch, wenn er auch einen erkennbaren Mehrwert bietet. Dieser Abschnitt zeigt einige der Vorteile, die durch den intelligenten Einsatz einer Microservice-Architektur entstehen können [Fowa; New15].

Es ist wichtig zu verstehen, dass die Vorteile, die durch Microservices entstehen, erst ab einer gewissen Größe bzw. Komplexität des Gesamtsystems zum Tragen kommen. In einfachen Softwaresystemen steht die Komplexität der Microservice-Architektur in keinem angemessenen Verhältnis zu deren Vorteilen [Fowb].

1.3.1 Heterogener Technologieeinsatz

Beim monolithischen Ansatz sind die Technologieentscheidungen äußerst eingeschränkt [Fowa]. Nachdem die Haupttechnologie festgelegt ist, kann aus diesem Korsett nur noch geringfügig ausgebrochen werden. Aber nicht für alle Aufgaben muss der eingeschlagene Weg auch der optimale sein.

Hier kommt ein wesentlicher Vorteil von Microservices zum Tragen. Da jeder Dienst eine kleine autonome Komponente ist, sind für jeden Dienst unterschiedliche sinnvolle Technologieentscheidungen möglich. Selbst die Wahl des Speichermechanismus kann individuell erfolgen. Die eingesetzte Technologie kann beispielsweise von der Aufgabenstellung oder den Fähigkeiten der Teammitglieder abhängig gemacht werden. Damit werden die Technologieentscheidungen nicht mehr von zentraler Stelle gesteuert, sondern die Kompetenz in die einzelnen Teams verlagert.

Die Macht der freien Technologieauswahl ist aber mit Bedacht einzusetzen. Es kann für ein System auch kontraproduktiv sein, wenn zu viele Technologien eingesetzt werden, die womöglich noch nicht einmal ein stabiles Sta-

dion erreicht haben. Daher macht die Definition von Team-übergreifenden Richtlinien zur Technologieauswahl durchaus Sinn. Der entscheidende Vorteil gegenüber dem monolithischen Ansatz ist aber die Wahlfreiheit, auch nach dem Start der Entwicklung.

1.3.2 Robustheit

Durch den hohen Modularisierungsgrad in einer Microservice-Architektur herrscht ein ganz anderes Verständnis bezüglich der Verfügbarkeit von einzelnen Komponenten, wie in einer monolithischen Architektur. In einer monolithischen Anwendung befinden sich nämlich alle Komponenten in einem einzelnen Prozess. Daher kann ein Entwickler davon ausgehen, dass alle Komponenten immer verfügbar sind. Nicht so in einer Microservice-Architektur. Hier muss jederzeit davon ausgegangen werden, dass Dienste nur eingeschränkt oder gar nicht verfügbar sind.

Wenn eine monolithische Anwendung ausfällt, ist das ganze System nicht mehr verwendbar. Im Gegensatz dazu kann das Gesamtsystem trotz des Ausfalls eines oder mehrere Microservices, zumindest eingeschränkt, weiterlaufen.

1.3.3 Einfaches Deployment

Jedes Release einer großen monolithischen Anwendung stellt ein gewisses Risiko dar. Daher passieren solche Releases in eher großen Abständen. In einem agilen Umfeld sind derartige lange Releasezyklen nicht tragbar. Außerdem kann jede kleine Fehlfunktion das ganze Deployment zum Scheitern bringen.

Mit Microservices ist es möglich, jeden Dienst einzeln auszurollen. Damit ist die Auswirkung aus Sicht des Gesamtsystems viel geringer. Wenn der Dienst nach dem Ausrollen einen Fehler aufweist, kann nur dieser eine Dienst auf den Ausgangszustand zurückgesetzt werden.

Auch die Abhängigkeiten zwischen den einzelnen Teams ist durch den Microservice-Ansatz reduziert. Ein Team kann ihren Service um Funktionalität erweitern und sofort ausrollen. Andere Teams, die diese Funktionalität verwenden wollen, können erst dann neu ausrollen wenn ihr Dienst stabil ist. Dafür ist es aber notwendig, dass alle Dienste ihre Schnittstellen stets rückwärtskompatibel halten.

Die in diesem Abschnitt beschriebenen Vorteile einer Microservices Architektur sind keinesfalls allumfassend. Je nach Einsatzgebiet kommen möglicherweise auch andere Vorteile stärker zum Tragen als die hier angeführten. Um von den Vorteilen profitieren zu können, ist eine ordentliche Umsetzung dieses Architekturmusters aber unumgänglich. Denn ansonsten hat man zwar die gesamte Komplexität die Microservices mit sich bringen, jedoch nicht die gewünschten Vorteile.

1.4 SOA

Ein kontrovers diskutiertes Thema im Bezug auf Microservices ist die Beziehung zu serviceorientierter Architektur, kurz SOA. Das abstrakte Architekturmuster SOA wurde bereits 1996 in [SN96] beschrieben und hat sich seither ständig weiterentwickelt.

Auch bei SOA ist es schwer, eine genaue Definition zu geben. Grundsätzlich handelt es sich dabei um eine lose gekoppelte Softwarearchitektur, in der die Komponenten der Software in Form von autonomen Diensten, um die Geschäftsprozesse gestaltet werden [BdH]. Neben dieser einfachen informellen Definition haften sich über die Jahre immer neue Konzepte an den Begriff an. Mittlerweile verbinden viele Architekten konkrete Technologien mit dem eigentlich abstrakten Konzept. Sehr häufig zählen dazu Technologien, wie SOAP, WSDL, WS-* Protokolle oder auch nachrichtenorientierte Middleware Lösungen, wie ESB [Fowd]. Aus diesem Grund stößt dieses Muster oft auf Ablehnung, da fälschlicherweise viele komplexe Technologien damit in Verbindung gebracht werden.

Newman beschreibt in [New15, S. 8], dass Microservices und SOA so wie Scrum und agile Softwareentwicklung miteinander in Beziehung stehen. Scrum ist eine konkrete Form von agiler Softwareentwicklung. So sind auch Microservices ein bestimmter Stil SOA umzusetzen. Da alle Konzepte einer Microservice Architektur auch in SOA enthalten sind, können Microservices als Teilmenge und Konkretisierung von SOA verstanden werden.

Oft wird SOA dafür kritisiert, viel zu abstrakt und breit gefächert zu sein. Es gibt viel zu wenig konkrete Hilfestellungen, beispielsweise für den Entwurf von Service-Grenzen oder die Bestimmung der Service-Größe. Das Konzept der Microservices hingegen wurde für einen bereits existierenden Stil der Anwendungsentwicklung nachträglich geprägt. Bei SOA hingegen wurde zuerst das Konzept definiert.

1.5 Zusammenfassung

In diesem Abschnitt wurden Microservices als um Geschäftskompetenzen entworfene, lose gekoppelte und autonome Dienste in einer serviceorientierten Architektur, definiert. Der Begriff Microservice dient als Sammelbegriff für viele Konzepte, die sich um dieses Architekturmuster scharen. Im Gegensatz zu SOA ist die Vorstellung, was Microservices sind, etwas konkreter. Sie lassen aber immer noch viel Interpretationsspielraum offen.

Monolithischen Anwendung bündeln sämtliche Funktionalität eines Systems in einem einzigen großen ausführbaren Prozess. Bei der Microservice-Architektur stehen wichtige Funktionalitäten als eigenständiger Dienst zur Verfügung. Das ermöglicht großen Teams die Arbeit an komplexen Aufgaben, ohne sich gegenseitig zu stören. Damit ist es jedem Team selbst überlas-

sen, die optimalen Technologieentscheidungen zu treffen, den Releasezyklus des Dienstes zu bestimmen und den Dienst in robuster Art und Weise zu implementieren.

Den Vorteilen der Microservice-Architektur steht aber eine nicht zu unterschätzende Komplexität gegenüber. Beispielsweise die Orchestrierung aller einzelnen Dienste zu einer Einheit stellt eine große Herausforderung dar. Außerdem fließt viel Arbeit in die saubere Definition der Schnittstellen zwischen den Diensten ein. Einfache Anpassungen können schnell ausarten, da sie mehrere Dienste betreffen können.

Nichtsdestotrotz hat das Microservice-Architekturmuster in vielen Einsatzgebieten seine Vorzüge. Am Beginn einer Microservice-Architektur sollte eine ausführliche Aneignung des erforderlichen Domänenwissens stehen. Oft funktioniert das nur durch den Start der Entwicklung mit einer monolithischen Architektur. Das Ziel sollte eine evolutionäre Architektur sein. Eine monolithische Architektur kann mit steigendem Verständnis für die Servicegrenzen leicht in eine Microservice-Architektur überführt werden.

Kapitel 2

Container-Technologien

Dieses Kapitel beschreibt mit der Betriebssystemvirtualisierung in Containern eine effektive Möglichkeit, Microservices mit allen Abhängigkeiten in eine Einheit zu verpacken und effizient zu betreiben. Die technischen Grundlagen und Voraussetzungen dafür existieren schon einige Jahre, doch erst eine Implementierung mit dem Namen *Docker* brachte neuen Aufschwung in diese Art der Virtualisierung. Mittlerweile ist Docker eine allgegenwärtige Methode, Software aller Art zu verteilen und zu betreiben.

Eine Microservices-Architektur ist nicht nur aus Softwareentwicklungssicht herausfordernd, sondern auch aus Infrastruktursicht. Jeder Microservice muss unabhängig ausgerollt und skaliert werden können. Nur so kann diese Architektur auch die in Abschnitt 1.3 beschriebenen Vorteile entfalten. Im Unterschied zu Hardwarevirtualisierung bietet dieser Ansatz wesentlich kürzere Bereitstellungszeiten und eine effektivere Nutzung von Ressourcen.

Jeder Service hat bestimmte Voraussetzungen an seine Infrastrukturumgebung. Dazu zählen externe Bibliotheken, Konfigurationen und meistens eine Laufzeitumgebung, wie z. B. Java, .NET oder Python. Nun gibt es drei Möglichkeiten, die Infrastruktur über den gesamten Lebenszyklus eines Services zu verwalten. Am schlechtesten ist die benötigte Konfiguration manuell vorzunehmen. Dadurch ist es schwierig Änderungen nachzuvollziehen und zu testen. Besser ist es die Abhängigkeiten auf einem Server mit *Infrastructure-as-Code* zu installieren und laufend zu aktualisieren. Ein alternativer Ansatz ist, den Service mit seinen Abhängigkeiten und Konfigurationen in ein Betriebssystemabbild – *engl. Image* – zu verpacken [New15, S. 113]. Anstelle einer ausführbaren Anwendung, wird einfach ein vollständiges Abbild eines virtuellen Servers erstellt und verteilt. Im folgenden Abschnitt wird dieser Ansatz noch näher präzisiert und anschließend mit Docker eine Technologie vorgestellt, die genau auf dieser Idee aufsetzt.

2.1 Unveränderbarer Server

Anstatt die Konfiguration eines Servers zu ändern, kann man ihn auch stoppen und einen neuen Server mit aktualisierter Konfiguration wieder starten. Was sich anfänglich sehr aufwändig und unsinnig anhört, ist heute aus gutem Grund gängige Praxis. Das Unternehmen Netflix beispielsweise, praktizierte diesen Ansatz bereits sehr früh [Orz]. Laut eigenen Angaben konnten sie dadurch die Reproduzierbarkeit und Stabilität ihres Softwareauslieferungsprozesses stark verbessern. Zurückzuführen ist das auf die Tatsache, dass die in der Testumgebung validierten Artefakte identisch zu den im Produktivsystem eingesetzten sind. Des weiteren gibt es keine Möglichkeit, wie eine Konfigurationsänderung unabsichtlich in ein Produktivsystem gelangen kann, ohne dass diese durch eine Reihe von Tests validiert wurde. Unter einem unveränderbaren Server versteht man also eine Ressource, die niemals verändert, sondern nur durch eine aktualisierte Version ersetzt wird [Mor].

2.2 Arten von Virtualisierung

Vor dem Einstieg in Container-Technologien lohnt sich ein genauerer Blick auf verschiedene Virtualisierungstechniken. Nur wer die Eigenschaften der verschiedenen Systeme kennt, kann objektiv entscheiden, in welcher Situation welche Technologie vorteilhaft ist. Daher bietet dieser Abschnitt eine Darstellung verschiedener Virtualisierungskonzepte.

Unter Virtualisierung versteht man die Illusion, mehrere virtuelle und voneinander unabhängige Server auf einem einzigen physischen System auszuführen. Zum einen ermöglicht das eine effektivere Nutzung von Ressourcen und zum anderen die Möglichkeit, Server per Software zu verwalten. Über die Jahre wurden viele verschiedene Arten von Virtualisierung entwickelt. [Rib] und [SN05] geben eine mögliche Klassifizierung verschiedener Ansätze. Nachfolgend sind nur diejenigen Arten beschrieben, die für den Kontext dieser Arbeit relevant sind.

Vollständige Virtualisierung

Bei der *vollständigen Virtualisierung* ermöglicht der sogenannte Hypervisor den Gastbetriebssystemen den Zugriff auf die Hardware. Die Gastsysteme sind unveränderte Betriebssysteme die keine Kenntnis darüber haben, dass sie virtualisiert sind. Für jeden Gast wird eine vollständige Hardwareumgebung simuliert. Dieser Ansatz schützt die Gastsysteme gegenseitig sehr effektiv. Er ist aber auch sehr aufwändig, da jedes Gastsystem ein vollständiges Betriebssystem benötigt.

Paravirtualisierung

Wenn das Gastsystem Kenntnis über die Virtualisierung hat, dann spricht man von *Paravirtualisierung*. Das Gastsystem verwendet sogenannte Hypercalls, um direkt mit dem Hypervisor zu interagieren. Damit lässt sich zwar eine Performanzverbesserung erzielen, jedoch ist dafür ein adaptiertes Gastbetriebssystem erforderlich. Diese Art der Virtualisierung kommt z. B. in der Microsoft Azure Cloud zum Einsatz [Kri10, S. 30]. Dort wird das Gastbetriebssystem als aufgeklärt – *engl. enlightend* – bezeichnet.

Prozessorunterstützte vollständige Virtualisierung

Für die *prozessorunterstützte vollständige Virtualisierung* greift der Hypervisor auf spezielle Prozessorfunktionen zurück. Der Befehlssatz dieser Prozessoren ist für Virtualisierungsszenarien erweitert, um eine Geschwindigkeitssteigerung zu erzielen und die Aufgaben des Hypervisors zu erleichtern. Durch die damit erreichte Komplexitätsreduktion der Hypervisorimplementierung, sind diese viel einfacher und robuster zu implementieren.

Betriebssystemvirtualisierung

Die *Betriebssystemvirtualisierung* unterscheidet sich stark von den anderen Arten. Hier gibt es keinen Hypervisor und auch die Gastsysteme sind keine vollständigen Betriebssysteme. Stattdessen werden sogenannte Container innerhalb eines Betriebssystems virtualisiert. Weil diese Art nur ein tatsächliches Betriebssystem erfordert und dieses von allen Containern genutzt wird, ist sie effizient und ressourcensparend. Eine wesentliche Einschränkung ist derzeit aber noch, dass Container und das Wirtssystem auf dem selben Betriebssystem basieren müssen.

2.3 Isolation versus Effizienz

Virtualisierung ist immer ein Kompromiss zwischen Effizienz und Isolation. Jede Art zieht die Grenzen zwischen diesen beiden Eigenschaften an einem anderen Punkt. Die Effizienz lässt sich einfach anhand quantitativer Kriterien, wie dem Durchsatz oder Latenzzeiten festmachen. Bei der Isolation gestaltet sich die Situation schwieriger. In [Sol+07] werden dazu folgende Kriterien herangezogen:

- *Fehlerisolation* ist gegeben, wenn ein Fehler in einem Gastsystem kein anderes Gastsystem beeinflussen kann.
- *Ressourcenisolation* stellt sicher, dass die vorhandenen Ressourcen gerecht bzw. kontrollierbar auf die Gastsysteme aufgeteilt werden.
- *Sicherheitsisolation* beschränkt den Zugriff auf Ressourcen wie dem Dateisystem, dem virtuellen Speicheradressraum oder dem Netzwerk.

Hypervisor- oder gleichbedeutend auch Hardwarevirtualisierung bietet bessere Isolation als Betriebssystemvirtualisierung, ist aber wesentlich ineffizienter. In vielen Szenarien, wie einer Microservice-Architektur, ist eine strenge Isolation nicht notwendig, sondern kann gegen Effizienz eingetauscht werden.

2.4 Docker

Die zur Zeit bekannteste Betriebssystemvirtualisierungssoftware ist Docker. Im Gegensatz zur Hardwarevirtualisierung wird auf die Emulation einer Hardwareumgebung verzichtet und stattdessen auf der Betriebssystemebene virtualisiert. Durch den Verzicht auf diese Indirektionsschicht ist dieser Ansatz wesentlich effizienter.

Im Gegensatz zu anderen Virtualisierungstechniken steht bei Docker die Auslieferung von Software im Vordergrund. Ähnlich wie eine Paketverwaltungssoftware kann Docker eine zentrale Stelle für die Verteilung von Software sein. Zusammengefasst erleichtert Docker den Bezug, die Installation, den Betrieb und die Aktualisierung von Software. Alle diese Möglichkeiten sind wertvolle Hilfsmittel bei der Realisierung einer Microservice-Architektur.

2.4.1 Begriffserklärung

Im Umfeld von Betriebssystemvirtualisierung und Docker gibt es einige wichtige Begriffe. In [EBT16] ist eine umfassende Taxonomie über die Konzepte und Bestandteile von Container-Technologien zu finden. Ein kleiner Ausschnitt daraus sind folgende grundlegenden Begriffe:

- Ein *Image* ist die Vorlage für einen Container.
- Das *Dockerfile* ist eine textuelle Beschreibung eines Images. Aufgrund dieser Beschreibung wird schlussendlich das Image erstellt.
- Ein *Container* ist eine Laufzeitinstanz eines Images. Es kann beliebig viele Container-Instanzen von einem Image geben. Auf Prozessebene besteht ein Container aus einem oder mehreren Prozessen, die von anderen Container- oder Host-Prozessen isoliert sind. Durch die Isolation wirkt es für einen Container-Prozess, als hätte er ein vollständiges Betriebssystem zur Verfügung.

Der nächste Abschnitt beschreibt mit den zuvor definierten Begriffen den grundsätzlichen Aufbau von Docker. Darüber hinaus werden signifikante Unterschiede zu Hardwarevirtualisierung hervorgehoben.

2.4.2 Docker-Architektur

Docker implementiert eine klassische Client-Server-Architektur. Der Serverteil wird als *Docker-Engine* oder *Docker-Daemon* bezeichnet. Er interagiert

direkt mit dem Betriebssystem, das schlussendlich die tatsächliche Virtualisierung realisiert. Der Server bietet eine REST-Schnittstelle an, über die Klienten unterschiedlichster Art mit ihm kommunizieren können. Danut können sie z. B. Images erstellen, Container starten, stoppen oder löschen.

Um ein Image zu erstellen, sendet der Klient die Beschreibung in Form des „Dockerfile“ und die benötigten Dateien an den Server. Dieser erstellt ein Image, das auf Basis der Beschreibung konfiguriert und mit allen benötigten Abhängigkeiten ausgestattet ist. Ausgehend von einem Image kann der Klient beliebig viele Container starten. In Abbildung 2.1 ist dieser Ablauf noch einmal visuell dargestellt.

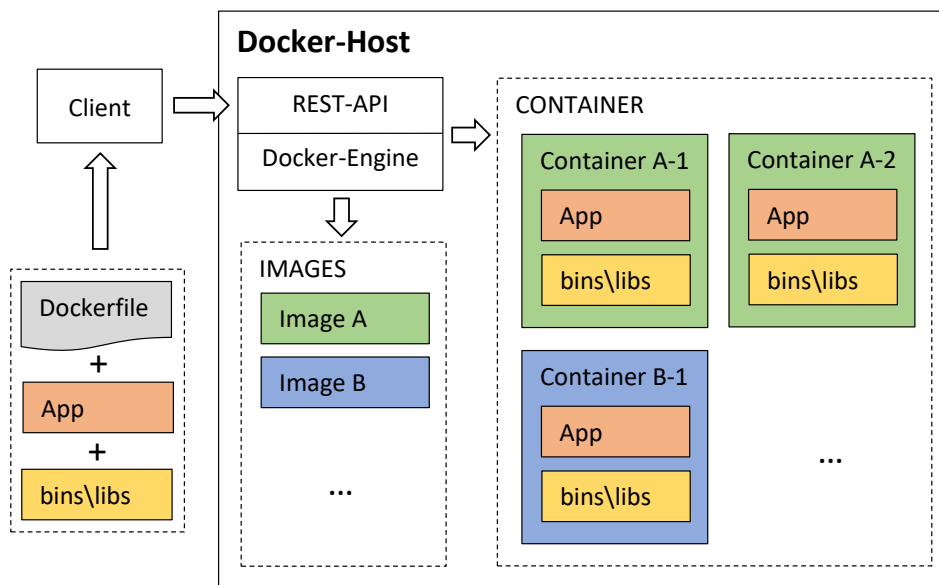


Abbildung 2.1: Docker-Architektur

Die genaue technische Umsetzung der Virtualisierung ist für des Betriebssystem spezifisch und übersteigt den Rahmen dieser Arbeit. Der folgende Abschnitt beschreibt nur einen komprimierten Überblick über einige grundlegende Konzepte im Betriebssystem Linux.

2.4.3 Voraussetzungen für Betriebssystemvirtualisierung

Ein Container ist nur auf der Betriebssystemebene von anderen Containern isoliert. Im Prinzip sind die in einem Container gestarteten Anwendungen gewöhnliche Betriebssystemprozesse im Wirtssystem. Dennoch ist ein Container mehr ein virtuelles Betriebssystem als ein einfacher Prozess.

Die nachfolgenden Abschnitte basieren auf [Mer14], sowie [Bui15] und beschreiben einige Betriebssystemkomponenten, die für die Virtualisierung verantwortlich sind.

Namensräume

Namensräume bezeichnen im Betriebssystem *Linux* eine Technologie, mit der Betriebssystemressourcen gruppiert und somit voneinander isoliert werden können. Dazu zählen beispielsweise Prozesse, Netzwerkverbindungen, das Dateisystem, usw. Diese Technologie stellt somit die Isolation zwischen Containern und auch zum Wirtssystem sicher.

Kontrollgruppen

Wie Abschnitt 2.3 schon dargestellt hat, ist eine faire Ressourcenaufteilung zwischen Containern sehr wichtig. Linux bietet dafür das Konzept der Kontrollgruppen. Damit kann der Ressourcenverbrauch von Containern überwacht und gegebenenfalls deren Verbrauch limitiert werden.

Überlagerte Dateisysteme

Durch die Verwendung eines speziellen Dateisystems, kann Docker viele Daten zwischen Containern teilen und somit den Speicherplatz stark reduzieren. Die Grundidee ist, ein mehrschichtiges Dateisystem in eine einzige logische Sicht zu vereinen. Nur die oberste Schicht ist veränderbar. Alle anderen sind nicht beschreibbar und folglich unveränderbar. Eine Dateiänderung in einer höheren Schicht überdeckt die gleiche Datei einer niedrigeren Schicht.

Für beliebig viele Containerinstanzen ist somit nur eine einzige Kopie ihres Images auf der Festplatte notwendig. Mit dieser Technik ist eine enorme Speicherersparnis möglich, ohne die Isolation zu kompromittieren. Ein Betriebssystemabbild einer virtuellen Maschine mit Hardwarevirtualisierung ist um ein vielfaches größer und muss mehrfach abgespeichert werden. Je nach Betriebssystem gibt es verschiedene Implementierungen von überlagerten Dateisystemen. Zwei der bekanntesten Implementierungen sind das *Advanced Multi-Layered Unification Filesystem* und das *OverlayFS*.

2.4.4 Docker Beispiel

Programm 2.1 zeigt ein Beispiel für ein „Dockerfile“, dass ein Image mit einem Web-Service erstellt. Im Basis-Image ist bereits .NET Core – eine Abhängigkeit des Web-Services – vorinstalliert. Im Prinzip erhält die Beschreibung alle notwendigen Schritte, um den Web-Service auf einem leeren System zu installieren und zu konfigurieren. Die in Programm 2.2 angeführten Kommandozeilenbefehle, erzeugen aus der Imagebeschreibung aus Programm 2.1 zuerst ein ausführbares Image und startet dieses anschließend.

Programm 2.1: Beispiel für ein Dockerfile

```
1 FROM microsoft/dotnet:1.1.1-runtime
2 COPY published app
3 WORKDIR app
4 ENV ASPNETCORE_URLS http://+:80
5 EXPOSE 80
6 ENTRYPOINT [ "dotnet", "mywebapi.dll" ]
```

Programm 2.2: Docker Kommandozeilenbefehle

```
1 docker build -t sample-image .
2 docker run -d --rm -p 5000:80 sample-image
```

2.5 Microsoft Windows Container

Lange Zeit waren Container dem Betriebssystem Linux vorbehalten. Erst seit 2016 gibt es ein gleichwertiges Äquivalent für Windows Betriebssysteme [Fri]. Windows-Server-2016 ist das erste Windows Betriebssystem mit nativer Unterstützung für Betriebssystemvirtualisierung auf Basis von Docker. Auf vielen Servern kommt entweder das Betriebssystem Linux oder Windows zum Einsatz. Da Docker nun beide Systeme unterstützt, ist der potentielle Absatzmarkt sehr groß. Sowohl Linux- als auch Windows-Systeme halten sich an die selben Schnittstellen von Docker. Entwickler, die mit einem System vertraut sind, können ihr vorhandenes Wissen auch auf der anderen Plattform wiederverwenden.

In Linux sind Container, wie in Abschnitt 2.4.3 beschrieben, über Namensräume voneinander isoliert. Windows verwendet das selbe Konzept, jedoch gibt es eine weitere Variante, die eine strengere Isolierung ermöglicht. Bei den sogenannten Hyper-V-Containern läuft jeder Container in einer eigenen leichtgewichtigen und für Container optimierten virtuellen Hyper-V-Maschine [Küp]. Der Verwender kann somit sehr leicht zwischen Effizienz und Isolation wählen.

Jedes Image basiert auf einem anderen Image. Nur sogenannte Basis-Images besitzen kein Eltern-Image. Im Prinzip sind Basis-Images leere und auf das Minimum reduzierte Standardbetriebssysteme. Aufgrund der vielen verschiedenen Distributionen gibt es für Linux-Container sehr viele Basis-Images. Für Windows-Container hingegen gibt es nur zwei. Das sogenannte Windows-Server-Core-Image ist im Prinzip eine vollständige Windows-Server-2016 Installation, jedoch ohne Benutzeroberfläche. Die vielen gebotenen Möglichkeiten wirken sich aber enorm auf die Größe des Images aus. Eine schlankere Alternative ist das Nano-Server-Image. Diese abgespeck-

te Variante wurde speziell für Container entwickelt. Tabelle 2.1 zeigt den Speicherverbrauch von einigen ausgewählten Images und unterstreicht dabei die Leichtgewichtigkeit von Containern. Aufgrund der Wiederverwendbarkeit durch die geschachtelten Dateisysteme, ist der Speicherbedarf aber nicht so problematisch wie bei virtuellen Maschinen.

Tabelle 2.1: Image-Größe von ausgewählten Basis-Images (März 2017)

<i>Image</i>	<i>Plattform</i>	<i>Größe (entpackt)</i>
Ubuntu	Linux	128 MB
Debian	Linux	123 MB
CentOS	Linux	193 MB
Alpine	Linux	4 MB
Windows Server Core	Windows	10.1 GB
Windows Nano Server	Windows	1 GB

2.6 Containerverwaltung

Einen Container auf nur einem Server zu betreiben ist eine triviale Aufgabe, aber hunderte Container auf einem Cluster mit mehreren Servern, ist ein ungleich komplexeres Unterfangen [Rus]. Aber dieses Szenario ist in einer Microservice-Architektur eher die Regel als die Ausnahme. Um diese Herausforderungen zu bewältigen, wurden viele Werkzeuge für die Cluster- und Containerverwaltung entwickelt. Eine essentielle Funktion von diesen Werkzeugen ist es, mehrere Container zu einer logischen Einheit zusammenzuschließen, sodass diese auch als Einheit verwaltet werden können. Des weiteren bieten diese Werkzeuge eine Abstraktion der tatsächlichen Infrastruktur. So können mehrere Server zu einem Cluster verbunden und dieser als kohärente Plattform betrachtet werden.

Der Begriff Orchestrierung beschreibt in der Softwareentwicklung die Kombination mehrere Dienste zu einer Komposition. Auch bei Containern spricht man von Containerorchestrierung, wenn mehrere Container zu einer Einheit zusammengeschlossen werden, um ihren Lebenszyklus gemeinsam zu verwalten. Ein Orchestrierer wird von vielen anderen Komponenten, wie z. B. einem Scheduler oder einem Ressourcenmonitor unterstützt.

Die Technologielandschaft rund um Containerverwaltung ist sehr breit und befindet sich noch stark im Aufbau. Eine umfassende Betrachtung dieses großen Bereichs würde das Ausmaß dieser Arbeit übersteigen. Dennoch ist es für eine Arbeit wie diese, die sich mit dem Thema Microservices auseinandersetzt, unumgänglich, diesen wichtigen Teilbereich zu erwähnen. Daher

werden nachfolgend zumindest einige grundlegende Aspekte von Container-orchestrierung im Bezug auf Microservices dargestellt, die sich hauptsächlich auf [Ise] beziehen.

2.6.1 Funktionalität

Die Hauptaufgaben eines Containerorchestrierers sind Maschinenbelegungsplanung, Ressourcen- und Serviceverwaltung. All diese Funktionen ermöglichen eine Reihe nicht-funktionaler Eigenschaften, wie Skalierbarkeit, Verfügbarkeit oder Portabilität von Containern. Die einzelnen Produkte am Markt unterscheiden sich vom Funktionsumfang und der Umsetzung der einzelnen Funktion.

Maschinenbelegungsplanung

Ein Orchestrierer muss entscheiden, auf welchem Server eine oder mehrere Instanzen eines Containers erzeugt werden. Serverausfälle sollen automatisch erkannt und betroffene Container auf einem anderen Server neu gestartet werden. In manchen Fällen bieten sie auch eine Unterstützung bei der Aktualisierung von Containerversionen.

Ressourcenverwaltung

Alle Hardwareressourcen, die ein Container in Anspruch nehmen kann, müssen überwacht und limitiert werden. Grundsätzlich betrifft das den Prozessor und den Hauptspeicher, aber auch persistenten Speicher und Netzwerkressourcen.

Serviceverwaltung

Mehrere Container werden zu einer einzelnen Applikation zusammengefasst, um sie gemeinsam zu verwalten. Im Zuge dessen müssen auch Abhängigkeiten zwischen Containern berücksichtigt werden, um beispielsweise eine sinnvolle Startreihenfolge festzulegen. Damit schlussendlich eine Anwendung auch skalierbar und hoch verfügbar ist, sind Lastverteilungsmechanismen notwendig, die auch vom Orchestrierer verwaltet werden.

2.6.2 Verteilte Betriebssysteme

Ein Betriebssystem bietet Anwendungsprogrammen eine Schnittstelle zu den Systemressourcen eines Computers. Somit müssen sich Anwendungsprogramme nicht mit der tatsächlichen Interaktion mit einer konkreten Hardwarekomponente auseinandersetzen, sondern sie greifen auf die abstrakten Schnittstellen des Betriebssystems zurück. Auch Containerorchestrierungswerkzeuge können als eine Art Betriebssystem verstanden werden, jedoch

in verteilter Form. Statt Anwendungsprogramme teilt ein Orchestrierungswerkzeug Container bzw. aus vielen Containern zusammengesetzte Anwendungen, auf einen, mit einer Containervirtualisierungssoftware ausgestatteten, Rechner zu. Der Kern dieses Systems ist die Containervirtualisierungssoftware, die auf jedem der verteilten Rechner läuft und natürlich die Orchestrierungssoftware, mit den im vorherigen Abschnitt beschriebenen Funktionen. Die verteilten Rechner und ihr tatsächliches Host-Betriebssystem stellen die Systemressourcen dar. In vielen Fällen werden auch diese Systemressourcen als virtuelle Rechner zur Verfügung gestellt. In Abbildung 2.2 ist die Analogie zwischen Betriebssystemen und Containerorchestrierungswerkzeugen noch einmal dargestellt.




Abbildung 2.2: Vergleich eines Betriebssystems (links) und eines „verteilten Betriebssystems“ durch Containerorchestrierung

2.6.3 Marktanalyse

Studien, wie [Buc], sehen Container mit einer geschätzten jährlichen Wachstumsrate von bis zu 40 Prozent bis 2020 als einen der größten Zukunftsmärkte im Bereich Cloud-Computing. Aufgrund dieser Zahlen ist es auch nicht verwunderlich, dass in diesem Bereich sehr viel investiert wird und dementsprechend viele Produkte auf den Markt kommen.

Laut [CD16] ist Docker mit 94 Prozent in 2016 das meist verwendete System für Containervirtualisierung. Jedoch bei der Containerorchestrierung sieht selbige Studie derzeit eine ausgeglichene Marktaufteilung zwischen den Produkten *Docker Swarm*, *Kubernetes* und *Apache Mesos*, wobei *Kubernetes* die meisten Anteile dazugewinnen konnte.

2.7 Zusammenfassung

In diesem Kapitel wurde Betriebssystemvirtualisierung, im speziellen mit Docker, als mögliche Plattform für Microservices vorgestellt. Ähnlich wie mit virtuellen Maschinen, ist es mit Docker möglich, eine Anwendung mit allen Abhängigkeiten zu verpacken, zu verteilen und zu betreiben. Jedoch ist Virtualisierung mit Containern viel effizienter und benötigt weniger Speicherplatz als Hardwarevirtualisierung.

Es wird immer seltener, dass die Software und die Konfiguration einer Server-Infrastruktur laufend aktualisiert wird. Stattdessen werden diese langlebigen Server durch eine unveränderbare Infrastruktur ersetzt. Das heißt, anstatt einen Server zu aktualisieren, wird er durch einen neuen ersetzt. Unter einem Server ist in diesem Kontext meistens virtualisierter Server gemeint. Virtualisierungsplattformen wie Docker haben diesen Ansatz extrem effizient und robust gemacht.

Container alleine decken aber längst nicht alle Anforderungen an eine Infrastruktur für Microservices ab. Schnell sind Funktionen für die Skalierung, Verteilung, Aktualisierung oder die Überwachung von Containern notwendig. Für diese Aufgabe gibt es eine Menge von Containerorchestrierungswerkzeugen, die als eine Art verteiltes Betriebssystem über der Betriebssystemvirtualisierung agieren.

Unumstritten sind Container eines der zukunftssträchtesten Technologiefelder der letzten Jahre, getrieben durch die DevOps-Kultur und die Microservice-Architektur. Vor allem im Bereich von Cloud-Computing haben sie sehr großes Potenzial. Die Zukunft wird zeigen, ob und wie sich Container zwischen allen bestehenden Plattform-as-a-Service Angeboten platzieren können.

Kapitel 3

Serverlose Softwarearchitektur

Die Bereitstellung und der Betrieb von Software-Applikationen sind zwei oft unterschätzte Kostenfaktoren. Viele technologische Entwicklungen der letzten Jahre, wie etwa Hardware-Virtualisierung, Automatisierungswerkzeuge für Infrastruktur und Cloud-Computing, haben diese Kosten bereits stark reduziert. Dennoch ist der Einsatz einer selbst verwalteten Infrastruktur aufwändig und erfordert intensive Zusammenarbeit zwischen Entwicklern, IT-Administratoren und Release-Managern.

Vor der Bereitstellung einer monolithischen Software steht zuerst die Dimensionierung und Beschaffung der benötigten Hardware-Infrastruktur durch die IT-Abteilung. Diese muss danach noch an die Bedürfnisse und Voraussetzungen der Software angepasst werden. Die Installation der eigentlichen Software ist oft ein manueller oder halb-automatisierter Prozess. Das ist langsam und fehleranfällig, aber meistens akzeptabel, denn eine monolithische Software hat lange Release-Zyklen und besteht aus einem einzigen Artefakt. Erst das Microservice-Architekturmuster hat eine isolierte, agile und effiziente Bereitstellung von Software vorangetrieben.

Mit *Infrastructure-as-a-Service (IaaS)* bieten viele Cloud-Computing-Dienstleister die Möglichkeit, Server in wenigen Minuten bereitzustellen. Der Verwaltungsaufwand bleibt trotzdem relativ hoch, weil Betriebssystem-Updates, IT-Sicherheit, Netzwerkkonfiguration, usw. in der Verantwortung des Verwenders liegen. Viele Applikationen benötigen kaum Kontrolle über die Umgebung in der sie ausgeführt werden. Für diesen Fall ist die Verwendung eines *Platform-as-a-Service (PaaS)* Dienstes meistens vorteilhafter. Hier übernimmt der PaaS-Betreiber die vollständige Verwaltung der Hardware- und Betriebssystemebene. Der Dienstleistungsnehmer muss dafür nur seine Anwendung im richtigen Format bereitstellen, sowie die Kapazität und Skalierbarkeitseigenschaften festlegen.

Die Grundidee hinter *Serverless Computing*, ist dem Softwareentwickler

eine Plattform für die Bereitstellung von Diensten zu bieten, ohne dass sich dieser um Server, deren Konfiguration oder Kapazitätsmanagement kümmern muss. Bei IaaS und PaaS ist das nicht oder nur zum Teil gegeben.

Wie viele Konzepte im Microservice-Umfeld lässt sich auch serverlose Softwarearchitektur nur schwer abgrenzen. Im nächsten Abschnitt werden die zwei zur Zeit häufigsten Ausprägungsformen näher betrachtet.

3.1 Arten serverloser Softwarearchitektur

Serverlose Softwarearchitektur ist ein sehr junges Konzept, dessen weitere Zukunft noch offen ist. Derzeit haben sich aber schon zwei unterschiedliche Sichtweisen auf dieses Themengebiet herauskristallisiert [Rob].

In der älteren Sichtweise beschreibt der Begriff „*serverlos*“, Applikationen die sehr stark auf vollständig verwaltete Dienste von Cloud-Anbietern zurückgreifen. Darunter fallen beispielsweise verwaltete Datenbanken, Authentifizierungs- oder Benachrichtigungsdienste. Dieser Ansatz ersetzt also einen Großteil der Server-Logik durch Dienste von Drittanbietern. Daher hat sich auch die Bezeichnung *Backend-as-a-Service* dafür etabliert. Ein Teil der Applikationslogik muss aber dadurch vom Client übernommen werden. Mit JavaScript und verschiedenen Bibliotheken für die Erstellung von Benutzeroberflächen, lassen sich die dafür benötigten *Rich-Applications* effizient realisieren.

Seit etwa 2014 hat sich die Sichtweise durch die Einführung des Dienstes AWS-Lambda der Firma Amazon etwas geändert. Dieser Dienst erlaubt es, einfache ereignisgesteuerte Funktionen zu schreiben, die in der Cloud in einer zustandslosen Ausführungsumgebung vollständig verwaltet laufen. Diese Funktionen enthalten fast ausschließlich Geschäftslogik und werden in Skript-Dateien erstellt. Anstatt klobiger Artefakte können somit einfache Skript-Dateien verteilt werden. Weil Funktionen das zentrale Bereitstellungsformat sind, ist dieser Ansatz unter dem Namen *Functions-as-a-Service* (*FaaS*) bekannt. Der folgende Abschnitt beschäftigt sich intensiv mit dieser neuen Sichtweise auf serverlose Softwarearchitektur.

3.2 Functions-as-a-Service

Im Grunde erlaubt Functions-as-a-Service, kleine Aufgaben in Form von Funktionen zu programmieren und skalierbar, ohne weiteren Aufwand in der Cloud zu betreiben. Der Entwickler kann sich voll auf die Geschäftslogik seiner Applikation konzentrieren und muss sich kaum noch um Infrastrukturaufgaben kümmern.

Wie in den allermeisten Programmiersprachen, sind Funktionen in diesem Kontext eine relativ kleine Quelltexteinheit, die Eingangs- in Ausgangswerte transformiert. Die Aktivierung erfolgt bei Programmiersprachen durch

einen Funktionsaufruf. Hingegen bei FaaS, durch das Auftreten bestimmter vom Entwickler festgelegter Ereignisse. Beispiele für derartige Ereignisse sind folgende:

- Das Hinzufügen oder Manipulieren von Daten in einem Datenspeicher.
- Das Empfangen einer HTTP-Anfrage.
- Das Empfangen einer Nachricht von einem Nachrichtendienst.
- Das Auftreten eines zeitgesteuerten Ereignisses.

Eine Funktion ist nur dann sinnvoll, wenn sie auch Ausgaben oder zumindest Seiteneffekte produziert. In FaaS können diese wieder sehr vielfältig sein. Meistens ist das Ergebnis, die Interaktion mit einem anderen Cloud-Dienst wie z. B.:

- Das Hinzufügen oder Manipulieren von Daten in einem Datenspeicher.
- Das Senden einer HTTP-Antwort.
- Das Senden einer Nachricht an einen Nachrichtendienst.
- Das Versenden einer E-Mail.

Die folgenden Abschnitte beschreiben vielversprechende Anwendungsgebiete für FaaS. Des Weiteren werden die Konzepte FaaS und PaaS voneinander abgegrenzt.

3.2.1 Anwendungsgebiete

Für FaaS gibt es in den verschiedensten Bereichen sinnvolle Anwendungsgebiete. Hauptsächlich werden sie aber für kleine und abgeschlossene Funktionalitäten herangezogen. Beispielsweise eignet es sich sehr gut für die Konvertierung und Validierung von Daten. Eine Funktion kann auf ein bestimmtes Ereignis warten – z. B. dem Hinzufügen eines Elements in einer Warteschlange – und danach die gewünschte Funktionalität ausführen. Das Ergebnis der Funktion kann z. B. automatisch in eine Datenbank gespeichert oder an ein anderes System gesendet werden.

Microservice- und Cloud-Anwendungen verwenden oft eine große Anzahl an Cloud-Komponenten, wie verschiedenen Datenspeicher, Warteschlangen und Nachrichtendienste. Damit alle Einzelkomponenten in Summe ein funktionstüchtiges Gesamtsystem bilden, ist viel Logik für die Verbindung und Administration der Komponenten notwendig. Im Englischen wird diese Art von Logik häufig als „Glue-Code“ bezeichnet, weil er die Einzelteile zum einem Ganzen „zusammengeklebt“. Die Interaktion mit Cloud-Komponenten ist also ein essentielles Einsatzgebiet und ist deswegen ein großer Einflussfaktor auf das Programmiermodell von FaaS.

Der Erfolg der Microservice-Architektur und *FaaS* führte bereits zur Entstehung eines möglicherweise neuen Paradigmas: *Nanoservices* [Avr]. Bei Microservices stehen einzelne Geschäftsanforderungen im Vordergrund. Mit

Nanoservices werden einzelne Geschäftsanforderungen noch weiter auf Funktionsebene heruntergebrochen. Ein Beispiel für einen Microservice könnte ein Dienst für die Erstellung, Änderung und Nachverfolgung von Bestellungen in einem Online-Shop sein. Mit Nanoservices wäre jede einzelne dieser Funktionen ein eigener Dienst.

Amazon hat in [Bai+15] Vorschläge veröffentlicht, wie klassische Dreischicht-Architekturen, z. B. Web- oder Mobile-Anwendungen, mit serverlosen Technologie umgesetzt werden können. Darüber hinaus eignet sich FaaS aber genau so gut für Microservice-Architekturen. Die Einsatzgebiete sind daher sehr breit, was FaaS zu einem mächtigen Werkzeug macht.

Viel Potential besteht in neuen Domänen, wie *Internet of Things*, *Chat-Bots* oder *DevOps* [Bra]. In diesen Bereichen ist die Nachfrage nach kleinen, skalierbaren Programmen, die sich einfach entwickeln und betreiben lassen, sehr hoch. Durch die Einfachheit von FaaS eignet es sich auch sehr gut für den Prototypenbau.

3.2.2 Beziehung zu Platform-as-a-Service

In vielen Bereichen überschneiden sich die Möglichkeiten von FaaS mit denen anderer Technologien, wie z. B. PaaS. Dieser Umstand ist nicht weiter verwunderlich, da FaaS auf der Basis von PaaS aufbaut. Der signifikanteste Unterschied ist die ereignisgesteuerte Funktionsweise von FaaS. Funktionen werden nach dem Auftreten eines bestimmten Ereignis nur für die Dauer einer Aktivierung ausgeführt. Daher bezahlt der Verwender auch nur die Anzahl der Aufrufe und die Dauer der Ausführungszeit. Bei PaaS ist meistens zumindest eine ständig laufende virtuelle Maschine erforderlich, die auf Ereignisse wartet. Das verursacht Kosten, auch wenn die Maschine kaum oder gar nicht genutzt wird.

Skalierbarkeit ist in CloudComputing ein essentieller Faktor. PaaS bietet dafür die Möglichkeit, abhängig von Metriken wie Prozessorlast, die Anzahl der Instanzen auf denen die Anwendung ausgeführt wird, dynamisch zu erhöhen oder zu verringern. Dieser Ansatz erfordert bereits sehr wenig manuelles Eingreifen durch einen Entwickler oder Administrator. Aber FaaS geht hier noch einen Schritt weiter und erfordert praktisch keine manuellen Handlungen, um die Funktion skalierbar zu machen. Es ist die Aufgabe des Cloud-Anbieters, die Funktion automatisch zu skalieren. Weil die Funktionen zustandslos sind, kann man sie beliebig oft parallel ausführen.

Die Verwendung von PaaS schränkt Technologieentscheidungen stark ein, weil man sich auf eine konkrete Plattform bindet. Bei FaaS hingegen ist die Auswahl an möglichen Programmiersprachen sehr breit. Laufend fügen Cloud-Anbieter neue Sprachen hinzu. Damit ist die Technologieabhängigkeit durch die Verwendung von FaaS sehr viel geringer.

3.2.3 Markt

Alle namhaften Cloud-Anbieter, wie Amazon, Microsoft, IBM und Google haben bereits FaaS-Produkte in ihrem Angebot. Die nachfolgenden Abschnitte zeigen die Funktionsweise und Prinzipien anhand von *Microsoft-Azure-Functions*, da diese Implementierung unter der MIT-Lizenz Open-Source verfügbar ist und somit tiefe Einblicke in die Umsetzung bietet.

Amazon-AWS-Lambda ist von allen Produkten am längsten am Markt und bietet den größten Funktionsumfang. Jedoch haben auch die anderen Anbieter das Potential und die Nachfrage von FaaS erkannt und versuchen seither, den Entwicklungsrückstand zu schließen.

Derzeit befindet sich dieses doch recht neue Thema noch stark im Wandel. Es ist sehr wahrscheinlich, dass sich einige Dinge in naher Zukunft verändern werden. Die Grundideen haben aber alle Anbieter ähnlich umgesetzt. Trotzdem unterscheiden sie sich in einzelnen Punkten:

- Jeder Anbieter bietet unterschiedliche Programmiersprachen an. Es werden aber laufend neue Sprachen in die Produkte integriert.
- Auch wie das konkrete Skalierbarkeitsverhalten aussieht, muss beim jeweiligen Anbieter getestet werden.
- Meistens sind nur andere Dienste innerhalb des selben Cloud-Anbieters mit FaaS integriert. Dadurch kann sehr leicht eine starke Abhängigkeit zum gewählten Anbieter entstehen.
- Natürlich unterscheiden sich die einzelnen Angebote auch im Preis.

Derzeit investieren Cloud-Anbieter sehr viel in die Entwicklung ihrer *FaaS* Produkte. Das gibt einen Hinweis auf das große Potential dieser Technologie.

3.3 Azure-Functions

Im März 2016 veröffentlichte die Firma Microsoft eine Vorschauversion ihrer eigenen serverlosen Plattform mit dem Namen Azure-Functions [Mas]. Nur ein halbes Jahr später folgte die erste offizielle Version [Kir]. Azure-Functions ist eine Erweiterung der ohnehin schon sehr umfangreichen Microsoft Cloud-Plattform. Diese Technologie eignet sich vor allem für die ereignisgesteuerte Verarbeitung und Transformation von Daten aus verschiedenen Datenquellen. Das deklarative Programmiermodell von Azure-Functions ermöglicht eine einfache Interaktion mit Daten- und Ereignisquellen.

Microsoft griff für die Implementierung von Azure-Functions auf folgende, schon länger in Microsoft-Azure enthaltene, Dienste und Bibliotheken zurück [Chaa]:

- *App-Service-Web-App*
- *App-Service-Plan*

- *Site-Control-Manger (SCM)*
- *Web-Jobs*
- *Web-Jobs-SDK*

Folgende Neuentwicklungen waren tatsächlich notwendig:

- *Web-Jobs-SDK.Script*
- *App-Service-Function-App*
- *Dynamic-Hosting-Plan*

Die nachfolgenden Abschnitte geben einen Überblick über die hier aufgelisteten Bestandteile, die Entstehungsgeschichte und Anwendungsmöglichkeiten von Azure-Functions. Großteils beziehen sich die Grundlagen von App-Services und Web-Jobs auf [Rai15].

3.3.1 Azure-App-Service

App-Service ist in der Microsoft-Azure-Cloud ein Oberbegriff für Services, die in die Kategorie Platform-as-a-Service einzuordnen sind. Diese Services haben eine etwas konsequentere Interpretation von PaaS als die älteren Cloud-Services. Bei einem App-Service übernimmt Microsoft die Verwaltung der Infrastruktur, des Betriebssystems und der Laufzeitumgebungen.

Ein App-Service ist einem sogenannten App-Service-Plan zugeordnet. Dieser kann mehrere App-Services beinhalten, die dann auf einem oder mehreren Servern gemeinsam ausgeführt werden. Der App-Service-Plan ist also eine abstrakte Infrastrukturbeschreibung, in der die Anzahl, die Größe und das Skalierungsverhalten der virtuellen Maschinen festlegt. Daher wird er oft als „Server-Farm“ bezeichnet.

Der nächste Abschnitt beschreibt mit Azure-Web-Apps einen konkreten App-Service, der ein Grundbaustein von Azure-Functions ist.

Azure Web App

Eine Web-App ist in Microsoft-Azure der einfachste Weg, um eine Web-Anwendung bereitzustellen. Die virtuellen Maschinen des App-Service-Plan, in dem eine Web-App ausgeführt wird, sind bereits mit den gängigsten Webentwicklungsumgebungen ausgestattet. Damit lassen sich Web-Anwendungen unterschiedlicher Technologien, wie z. B. Node.js, .NET oder PHP, gemeinsam betreiben. Grundsätzlich ist eine Web-App ein abstrakter Web-Server.

3.3.2 Site-Control-Manager

Die Funktionalität eines App-Service und somit auch einer Web-App ist mit Hilfe von sogenannten Site-Extensions erweiterbar. Diese Erweiterungen werden im selben Kontext wie die eigentliche Web Anwendung ausgeführt.

Der Site-Control-Manager – oft auch KUDU genannt – ist eine Erweiterung, die bei jedem App-Service automatisch vorinstalliert ist.

Anfänglich war die einzige Aufgabe des Site-Control-Managers die Auslieferung des App-Services mittels Versionsverwaltungssystemen. Aber im Laufe der Zeit wurden weitere Funktionen ergänzt. Dazu zählt auch die Funktion Web-Jobs, welche die Abarbeitung von Hintergrundaufgaben ermöglicht. Für kleinere Aufgaben, für die eine eigene virtuelle Maschine überdimensioniert wäre, sind Web-Jobs oft eine wirtschaftlichere Alternative.

Web-Jobs

Als Web-Job eignen sich ausführbare Dateien oder unterstützte Skripte. Diese werden als eigener Prozess im Kontext eines App-Services entweder zeitgesteuert oder kontinuierlich ausgeführt. Damit können Hintergrundaufgaben überschüssige Kapazität ausnützen. Es kann aber auch zu negativen Effekten kommen, denn Hintergrundaufgaben können die Performanz der eigentlichen Web-Anwendung für den Endbenutzer beeinflussen.

3.3.3 Web-Jobs-SDK

Die Web-Jobs-SDK ist eine .NET-Bibliothek für die Implementierung ereignisgesteuerter Hintergrundaufgaben. Diese Bibliothek bietet eine reichhaltige Integration externer Datenquellen. Ein deklaratives Programmiermodell sorgt dafür, dass Entwickler die Anbindung an eine Datenquelle deklarativ beschreiben können, ohne selbst eine Zeile Quelltext zu schreiben [Chab].

Um vorab einen Einblick zu geben, zeigt Programm 3.1 beispielhaft die Verwendung dieser Bibliothek. Der nächste Abschnitt enthält dann eine detailliertere Aufarbeitung der verwendeten Konzepte. Die folgende Aufzählung gibt eine Übersicht wichtiger Aspekte des Einführungsbeispiels:

- Die Zeilen (1-5) definieren eine Datenstruktur mit drei Attributen.
- Zeile (7) startet die Laufzeitumgebung der Web-Jobs-SDK. Diese sucht per .NET-Reflection nach kompatiblen Funktionen.
- Zeile (10) definiert ereignisgesteuerte Funktion.
- Zeile (11) definiert das Ereignis, das einen Funktionsaufruf auslöst. Hier wird die Funktion bei jedem neuen Eintrag in einer Warteschlange aufgerufen und dessen Inhalt automatisch an den Funktionsparameter übergeben.
- Zeile (12) definiert einen Ausgangsparameter. Wertzuweisungen an diesen Parameter werden automatisch in dem konfigurierten *Blob Storage* gespeichert. Für den Pfad dieses Eintrags werden die aus dem Parameter in Zeile (11) übergebenen Werte extrahiert.
- Zeile (13) definiert einen weiteren Ausgangsparameter, der an eine andere Warteschlange weitergeleitet wird. Dieses Ereignis könnte wie-

derum einen anderen Funktionsaufruf auslösen.

Programm 3.1: Web-Jobs-SDK Beispiel

```
1 public class SensorData {
2     public string SensorId { get; set; }
3     public string Timestamp { get; set; }
4     public double Value { get; set; }
5 }
6 class Program {
7     static void Main() => new JobHost().RunAndBlock();
8 }
9 public class Functions {
10     public static void ProcessSensorData(
11         [QueueTrigger("sensorqueue")] SensorData sensorData,
12         [Blob("values/{SensorId}/{Timestamp}")] out string sensorValue,
13         [Queue("aggregationqueue")] out SensorData aggregationQueue) {
14         sensorValue = sensorData.Value.ToString();
15         aggregationQueue = sensorData;
16     }
17 }
```

Obwohl die Funktion in Programm 3.1 mit drei verschiedenen externen Datenquellen interagiert, enthält sie dafür fast keinen imperativen Quelltext, sondern lediglich eine deklarative Beschreibung in Form von Attributen. Die eigentliche Interaktion und das Warten auf Ereignisse ist die Aufgabe der Web-Jobs-SDK.

Eine Web-Job-Anwendung ist nichts anderes als eine gewöhnliche .NET-Applikation mit einer Referenz auf die Web-Jobs-SDK. Der nächste Abschnitt beschreibt, wie statische Methoden einer Web-Job-Anwendungen zu einem ereignisgesteuerten Web-Job werden.

Für viele Einsatzgebiete reicht dieses einfache, deklarative Programmiermodell aus. Es spricht aber nichts dagegen, die Interaktionslogik mit einer Datenquelle selbst im Funktionsrumpf zu implementieren. Das ist oft sogar notwendig, wenn der Funktionsumfang der deklarativen Variante nicht ausreicht. Der Grundgedanke ist jedoch, derartigen repetitiven Standardquelltext durch deklarative Programmierung zu vermeiden.

3.3.4 Bindungen

Bindungen definieren, wann eine Funktion aufgerufen wird und wie sie über ihre Funktionsparameter mit Datenquellen interagieren kann. Die zwei wesentlichen Web-Job-Bindungen sind Trigger-Bindungen und Nicht-Trigger-Bindungen. Erstere überwachen eine Ereignisquelle und lösen den Aufruf einer Job Funktion aus, wenn ein Ereignis auftritt. Zweitere binden Parameter einer Job Funktion an eine externe Datenquelle. Das kann sowohl zum Le-

sen, als auch zum Schreiben von Daten sein. Darum werden Nicht-Trigger-Bindungen in Eingangs- und Ausgangsbindungen eingeteilt. Jede Funktion muss genau eine Trigger-Bindung haben, kann aber beliebig viele Nicht-Trigger-Bindungen enthalten.

Es gibt bereits eine Vielzahl vorhandener Bindungen. Entwickler können die Bibliothek aber auch mit selbst oder von Drittanbietern entwickelten Bindungen erweitern. Dazu muss man die wichtigsten dafür notwendigen Klassen kennen. Abbildung 3.1 zeigt den Bindungsmechanismus von Nicht-Trigger-Bindungen in einem stark vereinfachten Klassendiagramm.

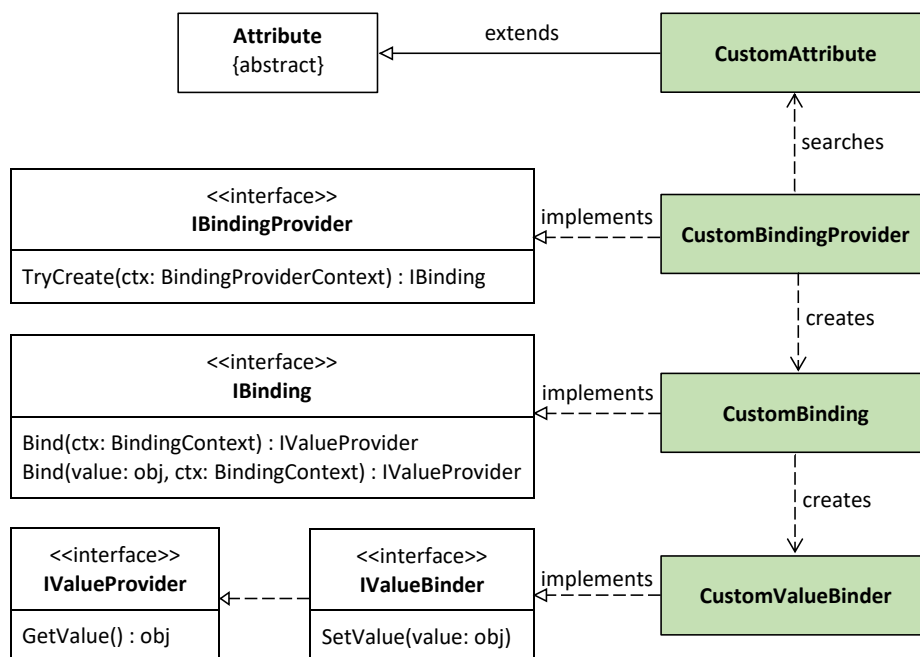


Abbildung 3.1: Web Jobs SDK Klassendiagramm (Nicht-Trigger-Bindung)

Wie [Chac] beschreibt, ist der Bindungsprozess in zwei Phasen eingeteilt. Die nächsten Abschnitte beschreiben diese Phasen und geben somit auch Aufschluss darüber, wie die in Abbildung 3.1 skizzierten Klassen in Zusammenhang stehen.

Startphase

Beim Starten der Anwendung werden Funktionen gesucht, die sich als Web-Job eignen. Dieser Prozess umfasst folgende Schritte:

1. Das Assembly der Anwendung wird nach allen Methoden in allen öffentlichen Klassen durchsucht.
2. Für jeden Parameter einer Methode wird versucht, eine Bindung zu erzeugen.

3. Jeder registrierte `I(Trigger)BindingProvider` bekommt die Möglichkeit eine Bindung über die Fabrikmethode `TryCreate` zu erstellen. Diese Methode überprüft den Datentyp des Parameters und meistens die Existenz des Bindungs-Attributs, welches die Metadaten der Bindung beinhaltet. Sind die Voraussetzungen einer konkreten Bindung erfüllt, wird diese erzeugt und zurückgegeben.
4. Wenn alle Parameter gebunden werden konnten, wird die Funktion in der Web-Jobs-Laufzeitumgebung registriert.
5. Für jede Trigger-Bindung wird zusätzlich die Überwachung der jeweiligen Ereignisquelle gestartet.

Laufzeitphase

Nachdem alle Funktionen identifiziert wurden, beginnt die Laufzeitphase. In dieser Phase passiert die tatsächliche Bindung der Funktionsparameter. Dieser Ablauf lässt sich wie folgt zusammenfassen:

1. Das Eintreten eines Ereignisses einer Trigger-Bindung führt zur Ausführung der assoziierten Job Funktion.
2. Für jeden gebundenen Parameter wird die `BindAsync` Methode der zur Startphase festgelegten Bindung aufgerufen. In dieser passiert der eigentliche Interaktionsschritt mit einer externen Datenquelle, wie z. B. dem Lesen von Daten aus einer Datenbank.
3. Oft unterstützen Bindungen verschiedene Parametertypen, wie z. B. `String` oder `Stream`. Die Bindung muss ihren tatsächlichen Wertebereich auf den Datentyp der aufzurufenden Funktion konvertieren.
4. Nachdem alle Parameter gebunden wurden, kann der eigentliche Funktionsrumpf aufgerufen werden.

3.3.5 Web-Jobs-Script-SDK

Die Web-Jobs-Script-SDK ist das Herzstück von Azure-Functions. Es ist eine .NET-Bibliothek, die eine interaktive Verwendung der sonst nur für .NET-Applikationen geeigneten Web-Jobs-SDK auch anderen Programmiersprachen zugänglich macht. Damit konnten die bereits für Web-Jobs entwickelten Bindungen für Azure-Functions wiederverwendet werden.

Wie in Programm 3.1 gezeigt, agiert die Klasse `JobHost` als Laufzeitumgebung von Web-Job-Funktionen. In der Web-Jobs-Script-SDK-Bibliothek ist die Klasse `ScriptHost` von `JobHost` abgeleitet und um dynamische Aspekte erweitert. Anstelle die Funktionen in eine .NET Anwendung zu verpacken, werden hier die Funktionen als Skript-Dateien in einer bestimmten Ordnerstruktur abgelegt. Die Skript-Laufzeitumgebung überwacht diese Ordnerstruktur auf Änderungen. Wenn eine Funktion hinzugefügt wird, löst das

unmittelbar eine Aktualisierung und bei kompilierten Sprachen eine erneute Übersetzung der Funktion aus.

Programmiermodell

Eine Azure-Function Applikation ist im Grunde nur eine Ordnerstruktur. Jede Funktion befindet sich in einem eigenen Ordner und enthält mindestens zwei Dateien. Meistens sind das eine Skript-Datei, mit dem eigentlichen Quelltext der Funktion und eine Konfigurationsdatei, in der die Metadaten der Parameterbindungen definiert sind. Abschnitt 3.3.3 hat die attributbasierte Definition der Bindungsmetadaten gezeigt. Für Azure-Functions ist diese Umsetzung untauglich, weil nicht alle Programmiersprachen einen derartigen Mechanismus besitzen.

Programm 3.2: Azure-Functions Beispiel C#

<pre>// function.json { "bindings": [{ "name": "sensorData", "type": "queueTrigger", "direction": "in", "queueName": "sensorqueue" }, { "type": "blob", "name": "sensorValue", "path": "values/{SensorId}/{Timestamp}", "direction": "out" }, { "type": "queue", "name": "aggregationQueue", "queueName": "aggregationqueue", "direction": "out" }] }</pre>	<pre>// run.csx public static void Run(SensorData sensorData, out string sensorValue, out SensorData aggregationQueue) { sensorValue = sensorData.Value.ToString(); aggregationQueue = sensorData; } public class SensorData { public string SensorId {get;set;} public string Timestamp {get;set;} public double Value {get;set;} }</pre>
---	--

Die in Programm 3.2 dargestellte Azure-Function ist funktional äquivalent zu der in Programm 3.1 gezeigten Variante mit Web-Jobs. Aus programmietechnischer Sicht ist der größte Unterschied, die Definition der Bindungsmetadaten in Form einer sprachunabhängigen Konfigurationsdatei, die auch für andere Sprachen verwendet werden kann. In diesem Beispiel ist der eigentliche Quelltext in einer C#-Skript-Datei implementiert, die aber durch jede andere unterstützte Sprache ausgetauscht werden könnte.

Der folgende Abschnitt beschreibt, wie die dynamische Übersetzung von Azure-Functions während der Laufzeit funktioniert.

Übersetzungsvorgang

Die Hauptaufgabe der Web-Jobs-Script-SDK-Bibliothek ist die dynamische Übersetzung der verschiedenen unterstützten Programmiersprachen und die Integration dieser dynamisch übersetzten Funktionen in die Web-Jobs-SDK-Laufzeitumgebung. Für jede Programmiersprache ist ein anderer Übersetzungsprozess notwendig. Nachfolgend wird dieser Prozess für die kompilierten Sprachen C# und F#, sowie für die interpretierte Sprache Javascript, kurz dargestellt.

Die *Roslyn-Compiler-API* ist eine .NET-Bibliothek, die unter anderem die Übersetzung von C#-Quelltext ermöglicht [Hej+12, S. 5]. Auch für die Sprache F# gibt es eine derartige Bibliothek. Die Skript-Laufzeitumgebung verwendet diese beiden Bibliotheken, um dynamisch C# und F# Skripte zu übersetzen und das Kompilat in ihren Prozess zu laden. Ab diesem Zeitpunkt kann die übersetzte Funktion ganz normal in der Web-Jobs-Laufzeitumgebung verwendet werden.

Wesentlich aufwändiger gestaltet sich die Interaktion mit der Web-Jobs-SDK, bei Sprachen die nicht der .NET-Familie angehören. Bei JavaScript-Funktionen beispielsweise, ist eine Brücke zwischen der .NET-*Common-Language-Runtime* und der JavaScript-Laufzeitumgebungen notwendig. Dieses Problem löst eine Bibliothek mit dem Namen *Edge.js*. Damit ist es möglich, .NET und *Node.js* Quellcode im selben Prozess auszuführen, indem beide Laufzeiten im selben Prozess geladen werden [Jan]. Das ist wesentlich effizienter, als beide Umgebungen getrennt auszuführen und über Interprozesskommunikation zu verbinden.

Die Programmiermodelle von .NET und *Node.js* unterscheiden sich teilweise gravierend. In *Node.js* wird Nebenläufigkeit beispielsweise durch Callback-basierte Programmierung gelöst, weil die virtuelle JavaScript-Maschine nur einen einzigen Ausführungsstrang nutzt. In .NET gibt es diese Einschränkung nicht. Hier wird Task-basierte Nebenläufigkeit bevorzugt. Programm 3.3 zeigt aber, dass beide Konzepte isomorph sind und sich darum trotzdem vereinbaren lassen.

Programm 3.3: Brücke zwischen Task-basierter Programmierung in .NET und Callback-basierter Programmierung in JavaScript

```
1 Func<object, Task<object> >  
2  
3
```

```
1 function (arguments, callback) {  
2   callback(error, result);  
3 }
```

Die Kompilierung oder Interpretation der Job Funktion zur Laufzeit, ermöglicht ein sehr effizientes ausrollen dieser Funktionen. Es muss nicht die ganze Host-Anwendung neu übersetzt und Ausgerollt werden, wie es bei den in Abschnitt 3.3.3 beschriebenen traditionellen Web-Jobs der Fall war.

3.3.6 Azure-Function-App

Eine Function-App ist in Microsoft-Azure ein auf die Bedürfnisse von Azure-Functions zugeschnittener App-Service, der mehrere zusammengehörende Azure-Functions zusammenbindet. Alle Arten von App-Services haben gemeinsame Basisfunktionen, wie z. B. Logging, Monitoring, Deployment-, sowie Skalierbarkeitsoptionen. Eine Function-App hat eine zusätzliche Site-Extension, in der die in Abschnitt 3.3.5 beschriebene Skript-Laufzeitumgebung ausgeführt wird. Auf diese Weise ist auch die Verwendung von HTTP-Triggern möglich, weil eine Site-Extension auch die Kommunikation über HTTP ermöglicht. Damit lassen sich mit Azure-Functions auch sehr schnell einfache Web-Services entwickeln. Alternativ wäre es auch möglich, die Skript-Laufzeitumgebung in einer .NET-Konsolenanwendung als kontinuierlichen Web-Job eines App-Service auszuführen. Damit wäre aber das Empfangen von HTTP-Anfragen nicht möglich.

Als zusätzliche Erweiterung bieten Function-Apps auch eine online Entwicklungsumgebung, die in das Microsoft-Azure-Portal integriert wurde. Somit können Funktionen interaktiv erstellt, geändert und gelöscht werden. Dateiänderungen werden automatisch von der Skript-Laufzeitumgebung erkannt und die geänderten Funktionen neu übersetzt. In der Entwurfsphase ist diese Möglichkeit der Entwicklung sehr produktiv. Danach sollte aber ein automatisierter Prozess, z. B. über ein Versionsverwaltungssystem, bevorzugt werden.

Der App-Service-Plan eines App-Service definiert, aus welchen und wie vielen virtuellen Servern die Infrastruktur bestehen soll. Die zur Verfügung gestellten Ressourcen stehen permanent zur Verfügung und verursachen somit auch laufend Kosten, wenn die Anwendungen keine Ressourcen beanspruchen. Dieses Konzept steht im Widerspruch zur Grundidee von Function-as-a-Service. Hier soll die Verrechnung auf Basis der Funktionsaufrufe erfolgen.

Für eine konsequente Implementierung von FaaS erweiterte Microsoft den klassischen App-Service-Plan um einen sogenannten *Consumption-Plan*. Mit dieser Variante hat der Entwickler keinerlei Möglichkeit mehr, die Skalierbarkeitseigenschaften zu bestimmen. Microsoft-Azure übernimmt völlig automatisch die Skalierung auf die optimale Größe.

Das Verrechnungsmodell bei einem Consumption-Plan stellt nur tatsächlich konsumierte Ressourcen in Rechnung. In vielen Fällen lassen sich damit Kostenersparnisse gegenüber Varianten mit reservierter Ressourcenzeit erzielen. Man verliert aber jegliche Einflussmöglichkeit auf die Ressourcen, sodass man beispielsweise das in Abschnitt 3.3.8 beschriebene Kaltstartproblem in Kauf nehmen muss.

Derzeit ist die Verwendung eines traditionellen App-Service-Plans und eines Consumption-Plans möglich. Konsumenten haben also die Wahlfreiheit oder können bestehende App-Service-Plans für Azure-Functions nutzen. Die

meisten anderen Anbieter am Markt haben nur ein dem Consumption-Plan ähnliches Modell im Angebot.

3.3.7 Verrechnungsmodell

Dieser Abschnitt bezieht sich auf den zuvor beschriebenen Consumption-Plan, da dieser die größte Übereinstimmung mit den Ideen hinter serverloser Softwarearchitektur hat. Die Kosten von Azure-Functions werden durch die Anzahl der Funktionsaufrufe und den Ressourcenkosten bestimmt. Für die Berechnung der Aufrufkosten wird die Anzahl der Funktionsaufrufe mit dem festgelegten Preis pro Aufruf multipliziert.

Hinter den Ressourcenkosten steckt eine aufwändigere Berechnung. Zuerst wird die Anzahl der Aufrufe mit der Aufrufdauer multipliziert, um den Ressourcenverbrauch in Sekunden zu ermitteln. Dieser Wert wird mit dem durchschnittlichen Speicherverbrauch in Gigabyte multipliziert. Danach erhält man den Ressourcenverbrauch in Gigabyte-Sekunden. Auch pro Gigabyte-Sekunde gibt es einen festgelegten Tarif, mit dem man die Ressourcenkosten berechnen kann.

Die Gesamtkosten setzen sich aus den Aufrufkosten und den Ressourcenkosten zusammen. Den Hauptteil der Kosten nehmen meistens die Ressourcenkosten ein, die abhängig vom Speicherverbrauch und der Aufrufdauer sind. In Tabelle 3.1 ist die gesamte Berechnung noch einmal verdeutlicht.

Bei einem klassischen App-Service-Plan berechnen sich die Kosten aus der Anzahl und Größe der virtuellen Maschinen. Aber wie bereits erwähnt, entspricht dieses Verrechnungsmodell nicht den Grundgedanken von Faas.

Tabelle 3.1: Azure-Functions-Preiskalkulation

<i>Anzahl der Aufrufe</i>	
*	<i>Aufrufdauer</i>
=	<i>Ressourcenverbrauch in Sekunden</i>
*	<i>Speicherverbrauch in GB</i>
=	<i>Ressourcenverbrauch in GB-s</i>
*	<i>Preis pro GB-s</i>
=	<i>Ressourcenverbrauchskosten</i>
<i>Anzahl der Aufrufe</i>	
	10^6
*	<i>Preis pro 10^6 Aufrufe</i>
=	<i>Aufrufkosten</i>
<i>Ressourcenverbrauchskosten</i>	
+	<i>Aufrufkosten</i>
=	<i>Gesamtkosten</i>


3.3.8 Kaltstart

Die dynamische Ressourcenbereitstellung des Consumption-Plans ermöglicht eine sehr feingranulare und kosteneffiziente Verrechnung von Funktionsaufrufen, jedoch hat diese Art auch Nachteile. Einer davon sind sogenannte Kaltstarts. Darunter versteht man den Effekt, dass der erste Funktionsaufruf nach längerer Inaktivität viel länger dauert, als durchschnittliche Aufrufe.

In AWS-Lambda werden Latenzzeiten von 100 bis 800 Millisekunden bei Node.js und bis zu 3500 Millisekunden bei Java Funktionen beobachtet [Ful16, Kap. 16]. Auch wenn AWS-Lambda und Azure-Functions mit völlig unterschiedlichen Technologien entwickelt wurden, leiden sie dennoch beide unter diesem Problem, wie das nachfolgende Experiment zeigt.

Um das Kaltstartproblem in Azure-Functions zu analysieren, wurden über einen Zeitraum von zwei Wochen, in mehreren Regionen in Microsoft-Azure, Funktionen über einen HTTP-Trigger aufgerufen. Die Aufrufe selbst erfolgten aus der selben Region und hatten einen Abstand zwischen fünfzehn Minuten und zwölf Stunden. Abbildung 3.2 zeigt, dass ein HTTP-Aufruf nach längerer Inaktivität durchschnittlich etwa vier Sekunden benötigt. Es ist aber auch zu erkennen, dass die Antwortzeiten sehr große Schwankungen aufweisen.

Abbildung 3.2: Latenzzeiten bei einem Azure-Functions-Kaltstart



Ob die großen Latenzzeiten nach einem Kaltstart ein Problem darstellen, kommt auf das jeweilige Einsatzgebiet an. Bei einem kontinuierlichen Lastaufkommen oder bei nicht zeitkritischen Szenarien, kann dieses Problem auch vernachlässigbar sein. In diesem Bereich herrscht sicherlich noch großes Optimierungspotential seitens der FaaS-Anbieter.

3.3.9 Zusammenfassung

In diesem Abschnitt wurde Azure-Functions als konkrete Technologie aus dem Bereich Function-as-a-Service vorgestellt. Es ist eine Möglichkeit, kleine unabhängige Funktionen ereignisgesteuert auszuführen. Die Alleinstellungsmerkmale sind die einfache Interaktion mit externen Datenquellen und das

serverlose Ressourcenmodell. Serverlos bedeutet nämlich, dass der Service-Anbieter sämtliche Infrastrukturaufgaben übernimmt, selbst die Skalierung.

Azure-Functions baut sehr stark auf die vorhandenen Funktionen der Web-Jobs-SDK auf und macht diese auch Programmiersprachen außerhalb der .NET-Familie zugänglich. Mit all seinen Bindungen und Triggern an verschiedenste Datenquellen, besitzt Azure-Functions einen reichhaltigen Baukasten für die Entwicklung von Microservices in der Cloud. Weil Funktionen automatisch hoch skalierbar und verfügbar sind, ist FaaS auch für anspruchsvolle Anwendungen geeignet. Spielt jedoch die Latenzzeit eine große Rolle, oder ist die Lastverteilung sehr hoch und vorhersehbar, sind andere Technologien möglicherweise besser geeignet.

In dieser Arbeit wurden keineswegs alle Möglichkeiten von Azure Functions betrachtet. Dazu zählen beispielsweise Sicherheit, Deployment oder Überwachung. Zudem befindet sich der ganze FaaS-Bereich noch stark in Entwicklung und wird deshalb ständig um neue Möglichkeiten ergänzt. Die Zukunft wird zeigen, wie sich dieser sehr junge Bereich entwickeln wird.

3.4 Evolution der Anwendungsentwicklung

Dieser Abschnitt bezieht sich überwiegend auf [Coca] und [Cocb], in denen der Autor Adrian Cockcroft die Evolution von monolithischer Software zu Microservices und weiter zu ereignisgesteuerten serverlosen Anwendungen beschreibt. Außerdem werden die dafür verantwortlichen technischen und organisatorischen Entwicklungen identifiziert.

Die Aufgabe von Software-Applikationen ist es, Geschäftswerte – *engl. business value* – zu generieren. Dazu müssen sie den Benutzern die enthaltene Geschäftslogik zugänglich machen. Eine Funktion kann erst Geschäftswerte erzeugen, wenn sie dem Benutzer tatsächlich zur Verfügung steht. Daher sollte für Unternehmen die Minimierung der Zeit zwischen der Erstellung der Geschäftslogik und der tatsächlichen Verfügbarkeit für den Endbenutzer an oberster Stelle stehen. Cockcroft beschreibt diesen Zusammenhang in folgender Formel:

$$Time\ to\ Value = Creation\ Cost + Delivery\ Cost$$

In der Vergangenheit war die Dauer zwischen der Erstellung und der Auslieferung einer neuen Funktion oft sehr lange. Aufgrund des hohen Aufwands und der zahlreichen Risiken eines neuen Releases, wurden Anwendungen nur in sehr großen Zeitabständen ausgeliefert. Zu dieser Zeit waren monolithische Anwendungen, in Verbindung mit einer oder wenigen zentralen relationalen Datenbanken, der effizienteste Weg, Geschäftslogik bereitzustellen. Performanzbedenken war der wesentlichste Einflussfaktor auf die Softwarearchitektur. Die folgenden drei Abschnitte erläutern wie Hardware-Fortschritte, Auslieferungsautomatisierung und organisatorische Verände-

rungen diese Probleme verringerten und somit den Weg für Microservices und serverlose Anwendungen ebneten.

3.4.1 Automatisierung der Softwareauslieferung

Vor einigen Jahren war die Bereitstellung von Software noch ein manueller Prozess. Die Beschaffung, Installation, Konfiguration und Aktualisierung von physischen Servern war ein wesentlicher Zeit- und Kostenfaktor. Wegen dieser langsamen Vorgänge wurden neue Versionen einer Anwendung nur selten ausgerollt. Einzelne Versionen mussten dementsprechend viel Geschäftslogik beinhalten, damit sich die Kosten der Bereitstellung amortisierten.

Eine zusätzliche Herausforderung stellte die Kapazitätsplanung dar. Die Trägheit der Infrastrukturbereitstellung führte zu einer chronischen Überdimensionierung der Systeme. Das führte wiederum zu einer unökonomischen Ressourcenauslastung.

Die Automatisierung von Infrastrukturaufgaben regte eine Überarbeitung festgefahrener Softwareauslieferungsprozesse an. Werkzeuge, wie *Chef* und *Puppet*, erlaubten es erstmals, Skripte für die automatische Provisionierung und Konfiguration von Infrastrukturkomponenten zu erstellen. Zu diesen Komponenten zählen Server, Betriebssystem, Netzwerk, Konfiguration, aber auch die Applikationssoftware selbst. Heute bezeichnet man diese Möglichkeiten als *Infrastructure-as-Code*, weil sich Infrastruktur mittels Quelltext erstellen und manipulieren lässt. [Hüt12, S. 135].

Wenn sich Infrastruktur wie Quelltext behandeln lässt, ist es naheliegend, dass auch Softwareentwickler an diesem Prozess teilnehmen. Die Infrastrukturprovisionierung und -verwaltung verlagerte sich allmählich von den IT- in die Softwareentwicklungsabteilungen. IT-Abteilungen und Cloud-Anbieter stellten den Entwicklern nur noch Programmierschnittstellen – auch API genannt – zur Verfügung, mit denen sie selbst die Infrastruktur nach ihren Bedürfnissen erzeugen und verändern konnten. Diese Zeit- und Kostenreduktion bei der Softwareauslieferung ermöglichten häufigere Releases. Schlussendlich war das eine der Voraussetzungen für die Microservice-Architektur, da von nun an eine effiziente Bereitstellung von vielen kleinen Anwendungen möglich war. Die Auslieferung von Services veränderte sich von einem langsamen und risikoreichen, zu einem automatisierten, stabilen und kostengünstigen Prozess.

Alle Anbieter serverloser Plattformen haben auf die Erfahrungen der Vergangenheit aufgebaut und Automatisierbarkeit von Anfang an berücksichtigt. Manuell könnten Softwaresysteme mit einer großen Anzahl von Funktionen kaum gehandhabt werden.

3.4.2 Leistungsverbesserung der Hardware

Erst die Steigerung der Netzwerkübertragungs- und Festplattengeschwindigkeiten der jüngeren Vergangenheit, haben den Weg für echte serviceorientierte Architekturen geebnet. Obwohl die Ideen hinter SOA schon lange existieren, wurden sie aufgrund von Leistungsengpässen gar nicht oder nur unzureichend umgesetzt.

Nachrichtenorientierte Systeme bedeuten immer einen gewissen Mehraufwand für die Übertragung und Kodierung der Nachrichten. Die Netzwerkgeschwindigkeit hat sich in den letzten Jahren um das zehn- bis hundertfache gesteigert [DAm+]. In der Ethernet-Spezifikation *IEEE 802.3-2015* sind Übertragungsraten von bis zu 100 Gigabit pro Sekunde spezifiziert.

Ein weiterer Hemmschuh bei der Nachrichtenübertragung waren schwergewichtige, oft XML-basierte, Kodierungsprotokolle, wie z.B. SOAP. Erst die Entwicklung von leichtgewichtigeren bzw. effizienteren Protokollen, in Kombination mit den um Größenordnungen schnelleren Netzwerkverbindungen, leiteten den Siegeszug von nachrichtenorientierten Systemen ein.

Auch in der Speichertechnologie passierte durch die Ablösung von magnetischen Festplatten durch Solid-State-Festplatten ein weiterer essentieller Technologiefortschritt. Magnetische Festplatten sind ihren neuen Konkurrenten vor allem bei zufälligen Lesezugriffen deutlich unterlegen [RCC12]. Diese schlechten Zugriffszeiten waren der Grund für das Design großer monolithischer Datenbanken. Geschäftslogikfunktionen mussten viele Operation in einer Transaktion durchführen, um die langsamen Zugriffszeiten zu kaschieren.

Auf Basis der sehr schnellen Solid-State-Festplatten wurden eine Menge neuer *NoSQL* Datenbanken entwickelt. Diese wiederum haben die Dezentralisierung und die in Abschnitt 1.2.3 beschriebene polyglotte Persistenz der bis dato hauptsächlich monolithischen Applikation vorangetrieben.

Auch Funktionen in FaaS machen intensiven Gebrauch von Nachrichtenübertragung und verschiedenen Datenspeichern. Im Grunde transformieren sie Daten, wann immer sie über eine Ereignis benachrichtigt werden.

3.4.3 Organisatorische Veränderungen

Abschnitt 1.2.1 hat bereits beschrieben, dass die Implementierung einer Microservice-Architektur mit großer Wahrscheinlichkeit eine organisatorische Umstrukturierung mit sich bringt. Projekt- oder technologiebezogene Strukturen sollten in produktbezogene umgewandelt werden. Um die Autonomie zu steigern und den Koordinationsaufwand zu senken, ist es empfehlenswert, große Teams in kleinere Einheiten zu zerteilen. Jedes dieser kleinen Teams ist für den gesamten Lebenszyklus eines oder mehrerer Dienste verantwortlich. Diese Struktur erlaubte eine viel agilere Entwicklung und erfordert weniger definierte Prozesse.

Jedes Unternehmen das ein Informationssystem entwirft, wird unvermeidbar eine Architektur hervorbringen, die ein Abbild der Organisationsstruktur ist [Con68]. Diese Aussage ist als das Gesetz von *Conway* bekannt. Aus diesem Grund ist für eine erfolgreiche Umsetzung von Microservices auch die richtige Organisationsstruktur eine unabdingbare Voraussetzung.

3.4.4 Von Microservices zu serverlosen Anwendungen

Wenn man Microservices auf die Spitze treibt, erfüllt jeder Service nur noch eine einzige Aufgabe. Aufgrund der großen Anzahl von Services in einer Microservice-Architektur, erfordert dieser Ansatz eine extrem effiziente Bereitstellung von Services. Selbst automatisch erstellte virtuelle Server und Container sind dafür nicht ausreichend. Für diese Anforderung ist Function-as-a-Service eine gute Wahl, denn Funktionen lassen sich in Bruchteilen einer Sekunde ausrollen.

Viele Services werden nur selten oder sehr unregelmäßig genutzt. In diesen Szenarien ist es schwierig, mit Containern oder virtuellen Maschinen die Kapazität zum richtigen Zeitpunkt bereitzustellen. Die Auslastung der Ressourcen ist in solchen Fällen meistens nicht optimal. Function-as-a-Service ist eine gute Möglichkeit, um mit volatilen Lastaufkommen umzugehen. Anstatt Rechenkapazität dezidiert zu reservieren, werden Funktionen erst bei Bedarf ausgerollt.

Funktionen enthalten beinahe ausschließlich Geschäftslogik. Es ist kaum Standard- oder Plattformquelltext notwendig. Damit gelingt es Entwicklern oft binnen weniger Tage, neue Funktionen zu entwickeln. Dabei verbinden sie einfach eine Funktion mit anderen Funktionen oder Services von Drittanbietern. Ein großer Vorteil von Function-as-a-Service ist, dass die entwickelten Funktionen automatisch hoch skalierbar und hoch verfügbar sind.

Alle zuvor beschriebenen Eigenschaften machen FaaS zu einer wertvollen Ergänzung der Microservice-Architektur. Es gibt aber durchaus Szenarien, in denen es nicht gut geeignet ist, beispielsweise wenn die Last sehr groß und vorhersehbar ist.

Quellenverzeichnis

Literatur

- [Bai+15] Andrew Baird, Stefano Buliani, Vyom Nagrani und Ajay Nair. „AWS Serverless Multi-Tier Architectures“. In: Nov. 2015. URL: https://d0.awsstatic.com/whitepapers/AWS_Serverless_Multi-Tier_Architectures.pdf (siehe S. 26).
- [Bre00] Eric A. Brewer. „Towards Robust Distributed Systems (Abstract)“. In: *Proceedings of the Nineteenth Annual ACM Symposium on Principles of Distributed Computing*. PODC '00. Portland, Oregon, USA: ACM, 2000, S. 7–. URL: <http://doi.acm.org/10.1145/343477.343502> (siehe S. 7).
- [Bui15] Thanh Bui. „Analysis of Docker Security“. *CoRR* abs/1501.02967 (2015) (siehe S. 16).
- [CD16] ClusterHQ und DevOps.com. *Container Market Adoption Survey*. Techn. Ber. 2016. URL: <https://clusterhq.com/assets/pdfs/state-of-container-usage-june-2016.pdf> (siehe S. 21).
- [Con68] Melvin E. Conway. „How Do Committees Invent?“ *Datamation* (Apr. 1968). URL: <http://www.melconway.com/research/committees.html> (siehe S. 41).
- [DAm+] John D'Ambrosia, Pete Anslow, David J. Law, Wael William Diab, Adam Healey, Steven B. Carlson und Valerie Maguire. *IEEE 802.3TM Industry Connections Ethernet Bandwidth Assessment*. Techn. Ber. URL: http://www.ieee802.org/3/ad_hoc/bwa/BWA_Report.pdf (besucht am 24.02.2017) (siehe S. 40).
- [EBT16] D. Ernst, D. Bernbach und S. Tai. „Understanding the Container Ecosystem: A Taxonomy of Building Blocks for Container Lifecycle and Cluster Management“. In: *Proceedings of the 2nd International Workshop on Container Technologies and Container Clouds (WoC 2016)*. IEEE, 2016 (siehe S. 15).

- [Fow02] Martin Fowler. *Patterns of Enterprise Application Architecture*. Boston, MA, USA: Addison-Wesley Longman Publishing Co., Inc., 2002 (siehe S. 2).
- [Ful16] Matthew Fuller. *AWS Lambda: A Guide to Serverless Microservices*. 2016 (siehe S. 37).
- [Hej+12] Anders Hejlsberg, Peter Golde, Matt Warren und Karen Ng. „The Roslyn Project: Exposing the C# and VB compiler’s code analysis“. In: Sep. 2012. URL: <https://www.microsoft.com/en-us/download/details.aspx?id=27744> (siehe S. 34).
- [Hor16] Christian Horsdal. *Microservices in .NET Core*. Manning, 2016 (siehe S. 4).
- [Hüt12] Michael Hüttermann. *DevOps for Developers*. 1st. Berkely, CA, USA: Apress, 2012 (siehe S. 39).
- [Kri10] Sriram Krishnan. *Programming Windows Azure: Programming the Microsoft Cloud*. O’Reilly, 2010 (siehe S. 14).
- [Mac+06] C. Matthew MacKenzie, Ken Laskey, Francis McCabe, Peter F. Brown und Metz Rebekah. *Reference Model for Service Oriented Architecture 1.0*. 2006 (siehe S. 1).
- [Mar06] Robert C. Martin. *Agile Principles, Patterns, and Practices in C#*. Prentie Hall, 2006 (siehe S. 4).
- [Mer14] Dirk Merkel. „Docker: Lightweight Linux Containers for Consistent Development and Deployment“. *Linux J.* 2014.239 (März 2014) (siehe S. 16).
- [New15] Sam Newman. *Building Microservices*. O’Reilly, 2015, S. 4–8 (siehe S. 8, 10, 12).
- [Rai15] Rick Rainey. *Azure Web Apps for Developers*. Microsoft Press, 2015 (siehe S. 28).
- [RCC12] Nathan Regola, David A. Cieslak und Nitesh V. Chawla. „The Constraints of Magnetic Versus Flash Disk Capabilities in Big Data Analysis“. In: *Proceedings of the 2Nd Workshop on Architectures and Systems for Big Data*. ASBD ’12. Portland, Oregon, USA: ACM, 2012, S. 4–9. URL: <http://doi.acm.org/10.1145/2379436.2379437> (siehe S. 40).
- [SN05] James E. Smith und Ravi Nair. „The Architecture of Virtual Machines“. *Computer* 38.5 (Mai 2005), S. 32–38. URL: <http://dx.doi.org/10.1109/MC.2005.173> (siehe S. 13).
- [SN96] Roy W Schulte und Yefim V Natis. „Service oriented architectures, part 1“. *Gartner, SSA Research Note SPA-401-068* (1996) (siehe S. 10).

- [Sol+07] Stephen Soltesz, Herbert Pötzl, Marc E. Fiuczynski, Andy Bavier und Larry Peterson. „Container-based Operating System Virtualization: A Scalable, High-performance Alternative to Hypervisors“. In: *Proceedings of the 2Nd ACM SIGOPS/EuroSys European Conference on Computer Systems 2007*. EuroSys '07. Lisbon, Portugal: ACM, 2007, S. 275–287 (siehe S. 14).

Online-Quellen

- [Avr] Abel Avram. *FaaS, PaaS, and the Benefits of the Serverless Architecture*. URL: <https://www.infoq.com/news/2016/06/faas-serverless-architecture> (besucht am 13. 10. 2016) (siehe S. 25).
- [BdH] Don Box, John deVadoss und Kris Horrocks. *SOA in the Real World*. URL: <https://msdn.microsoft.com/en-us/library/bb833022.aspx> (besucht am 15. 09. 2016) (siehe S. 10).
- [Bra] Mary Branscombe. *Microsoft Prepares for Serverless Computing with Azure Functions Preview*. URL: <http://thenewstack.io/azure-functions-serverless-computing-handling-iot-devices/> (besucht am 27. 10. 2016) (siehe S. 26).
- [Buc] Kaitlin Buckley. *451 Research: Application containers will be a \$2.7bn market by 2020*. URL: [https://451research.com/blog/1351-application-containers-will-be-a-\\$2-7bn-market-by-2020,-representing-a-small-but-high-growth-segment-of-the-cloud-enabling-technologies-market](https://451research.com/blog/1351-application-containers-will-be-a-$2-7bn-market-by-2020,-representing-a-small-but-high-growth-segment-of-the-cloud-enabling-technologies-market) (besucht am 21. 03. 2017) (siehe S. 21).
- [Chaa] Mathew Charles. *Azure Functions: The Journey*. URL: <https://blogs.msdn.microsoft.com/appserviceteam/2016/04/27/azure-functions-the-journey/> (besucht am 04. 03. 2017) (siehe S. 27).
- [Chab] Mathew Charles. *Binding Attributes*. URL: <https://github.com/Azure/azure-webjobs-sdk-extensions/wiki/Binding-Attributes> (besucht am 06. 03. 2017) (siehe S. 29).
- [Chac] Mathew Charles. *Binding Attributes*. URL: <https://github.com/Azure/azure-webjobs-sdk-extensions/wiki/The-Binding-Process> (besucht am 06. 03. 2017) (siehe S. 31).
- [Coca] Adrian Cockcroft. *Evolution of Business Logic from Monoliths through Microservices, to Functions*. URL: <https://read.acloud.guru/evolution-of-business-logic-from-monoliths-through-microservices-to-functions-ff464b95a44d> (besucht am 24. 02. 2017) (siehe S. 38).

- [Cocb] Adrian Cockcroft. *microXchg 2017 - Adrian Cockcroft: Shrinking Microservices to Functions*. URL: <https://www.youtube.com/watch?v=ZgxZCXouBkY> (besucht am 23.02.2017) (siehe S. 38).
- [Fowa] Martin Fowler. *Microservice Trade-Offs*. URL: <http://martinfowler.com/articles/microservice-trade-offs.html> (besucht am 17.09.2016) (siehe S. 8).
- [Fowb] Martin Fowler. *MicroservicePremium*. URL: <http://martinfowler.com/bliki/MicroservicePremium.html> (besucht am 17.09.2016) (siehe S. 8).
- [Fowc] Martin Fowler. *Microservices - a definition of this new architectural term*. URL: <http://martinfowler.com/articles/microservices.html> (besucht am 08.09.2016) (siehe S. 1, 2, 4).
- [Fowd] Martin Fowler. *Microservices - GOTO 2014*. URL: <https://www.youtube.com/watch?v=wgdBVIX9ifA> (besucht am 15.09.2016) (siehe S. 10).
- [Fowe] Martin Fowler. *Monolith First*. URL: <http://martinfowler.com/bliki/MonolithFirst.html> (besucht am 09.09.2016) (siehe S. 3).
- [Fowf] Martin Fowler. *PolyglotPersistence*. URL: <http://martinfowler.com/bliki/PolyglotPersistence.html> (besucht am 09.09.2016) (siehe S. 6).
- [Fri] Michael Friis. *Build and run your first Docker Windows Server Container*. URL: <https://blog.docker.com/2016/09/build-your-first-docker-windows-server-container/> (besucht am 23.03.2017) (siehe S. 18).
- [Ise] Karl Isenberg. *Container Orchestration Wars*. URL: https://www.youtube.com/watch?v=C_u4_l84ED8 (besucht am 21.03.2017) (siehe S. 20).
- [Jan] Tomasz Janczuk. *Run .NET and Node.js code in-process with Edge.js*. URL: https://www.infoq.com/articles/the_edge_of_net_and_node (besucht am 11.03.2017) (siehe S. 34).
- [Kir] Yochay Kiriati. *Announcing general availability of Azure Functions*. URL: <https://azure.microsoft.com/en-us/blog/announcing-general-availability-of-azure-functions/> (besucht am 04.03.2017) (siehe S. 27).
- [Küp] Marcel Küppers. *Container in Windows Server 2016: Funktionsweise, Typen, Anwendungen*. URL: <https://www.windowspro.de/marcel-kueppers/container-windows-server-2016-funktionsweise-typen-anwendungen> (besucht am 23.03.2017) (siehe S. 18).

- [Mas] Nir Mashkowski. *Introducing Azure Functions*. URL: <https://azure.microsoft.com/en-us/blog/introducing-azure-functions/> (besucht am 04.03.2017) (siehe S. 27).
- [Mor] Kief Morris. *ImmutableServer*. URL: <https://martinfowler.com/bliki/ImmutableServer.html> (besucht am 15.03.2017) (siehe S. 13).
- [Orz] Greg Orzell. *Building with Legos*. URL: <http://techblog.netflix.com/2011/08/building-with-legos.html> (besucht am 15.03.2017) (siehe S. 13).
- [Rib] Miguel Santos Ribeiro. *ImmutableServer*. URL: <https://itechthoughts.wordpress.com/2009/11/10/virtualization-basics/> (besucht am 15.03.2017) (siehe S. 13).
- [Rob] Mike Roberts. *Serverless Architectures*. URL: <http://martinfowler.com/articles/serverless.html> (besucht am 05.10.2016) (siehe S. 24).
- [Rus] Mark Russinovich. *Containers: Docker, Windows and Trends*. URL: <https://azure.microsoft.com/en-us/blog/containers-docker-windows-and-trends/> (besucht am 24.03.2017) (siehe S. 19).